

# Artificial Intelligence, Machine Learning and Deep Learning With Python

Bensearch solutions

[contact@bensearch-solutions.com](mailto:contact@bensearch-solutions.com)

June 12, 2024



**Bensearch  
solutions**

Business accelerator !

# Artificial Intelligence and Machine Learning 1

AI / ML

# Introduction à l'IA et au Machine Learning

- Qu'est ce que l'IA?
- Histoire de l'IA
- Machine Learning
- L'IA en robotique
- Introduction au Big Data et son intégration avec l'IA
- Éviter les pièges et travailler avec les données
- Principes du Machine Learning
- Avantages et inconvénients de l'IA et du ML
- Conclusion

# Questions clés pour comprendre l'impact quotidien de l'IA



Figure: Reconnaissance faciale

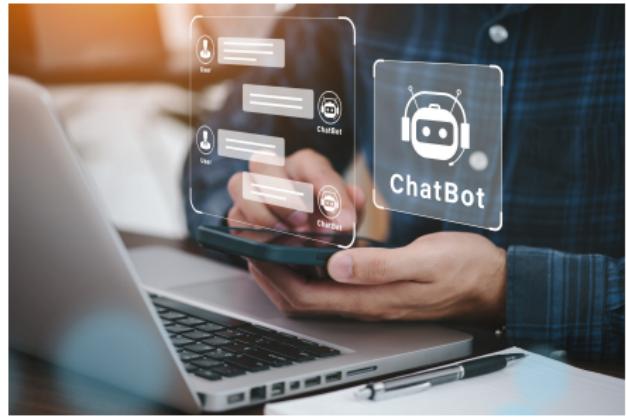


Figure: Application de chatbot

# Questions clés pour comprendre l'impact quotidien de l'IA



Figure: Classification d'emails



Figure: Suggestion d'amis facebook

# Questions clés pour comprendre l'impact quotidien de l'IA



Figure: Voiture autonome

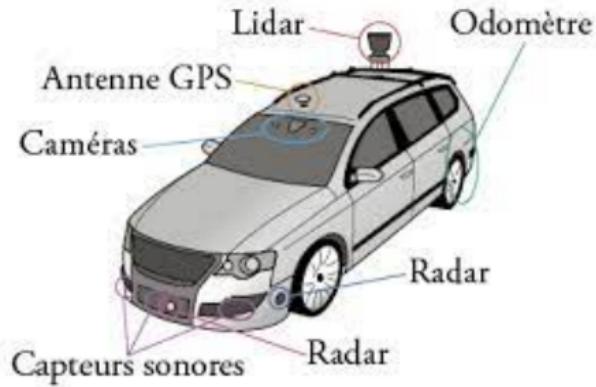


Figure: Composantes

Comment les voitures autonomes sont-elles capables de détecter et de réagir aux obstacles sur la route de manière autonome ?

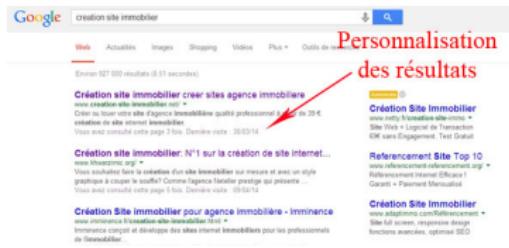
# Questions clés pour comprendre l'impact quotidien de l'IA



**Figure:** Assistant personnel intelligent de MS



**Figure:** Applications de reconnaissance vocale



**Figure:** Résultat de recherche personnalisée

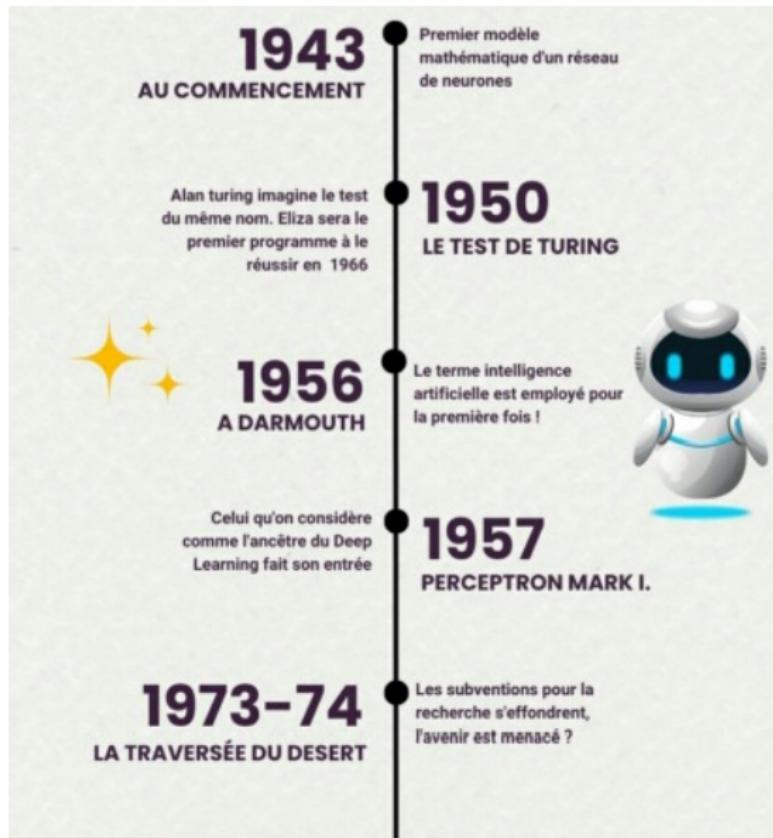


**Figure:** Application de traduction instantanée

# Définition de l'IA selon quelques auteurs

- **John McCarthy (1956)** : "L'IA est la science et l'ingénierie de la création de machines intelligentes, qui ont la capacité de réaliser des tâches qui nécessitent normalement l'intelligence humaine."
- **Stuart Russell et Peter Norvig (2009)** : "L'IA est le domaine de l'informatique qui traite de la création et de l'étude de machines qui peuvent effectuer des tâches qui, si elles étaient accomplies par des êtres humains, nécessiteraient de l'intelligence."
- **Marvin Minsky (1968)** : "L'IA est la construction de programmes informatiques qui peuvent accomplir des tâches qui, lorsqu'elles sont accomplies par des personnes, demandent de l'intelligence."

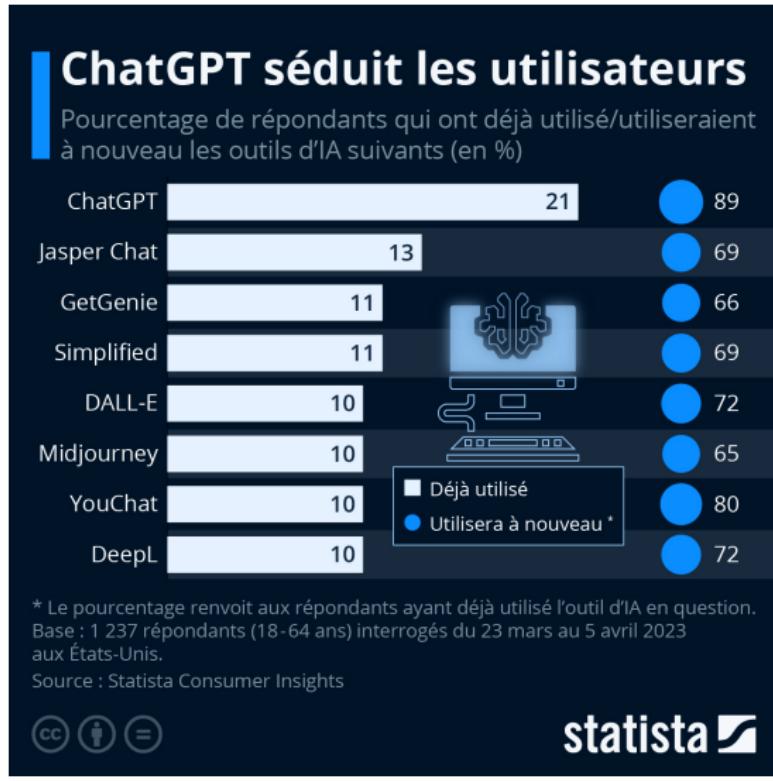
# Les dates clés de l'Intelligence Artificielle



# Les dates clés de l'Intelligence Artificielle



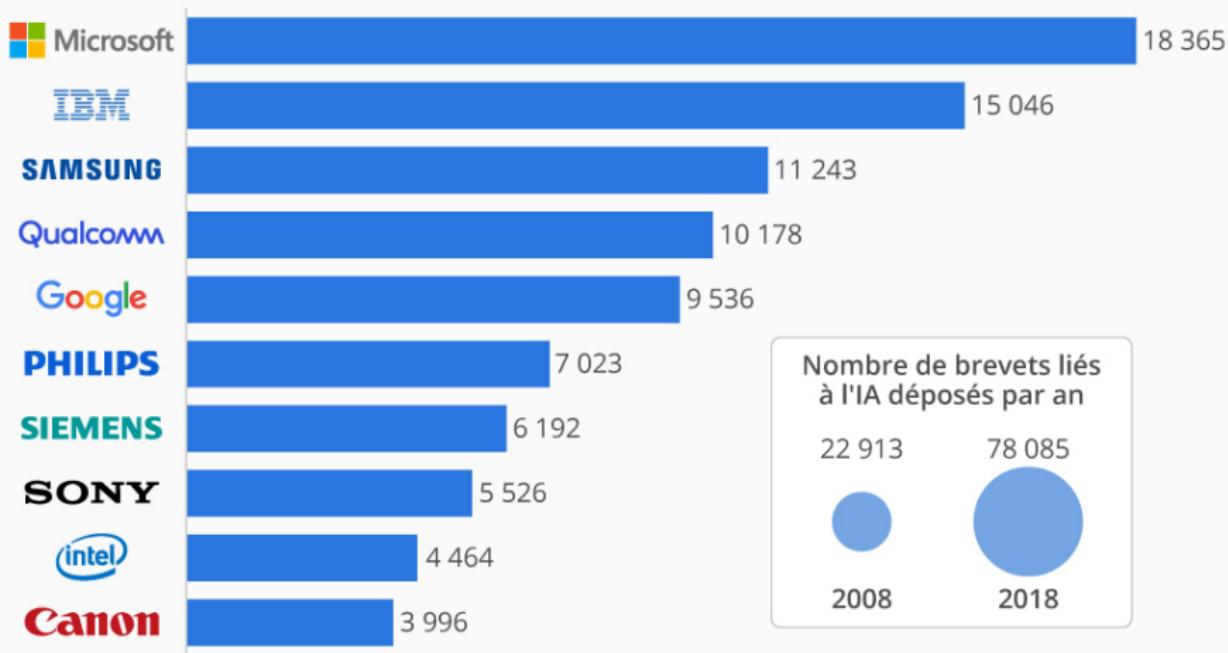
# Les Intelligences Artificielles populaires



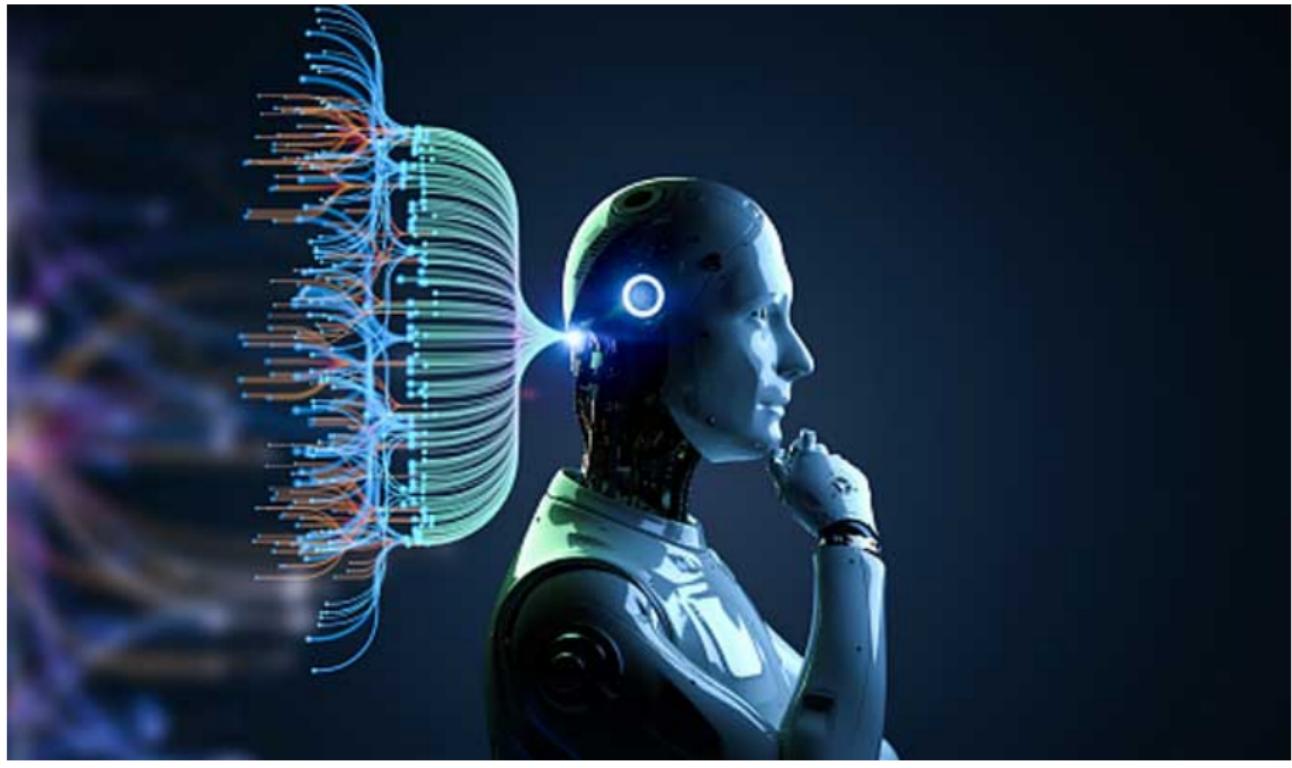
# La course vers les brevets

## La course aux brevets dans l'intelligence artificielle

Entreprises possédant le plus de brevets liés à l'intelligence artificielle \*



# Future de l'IA



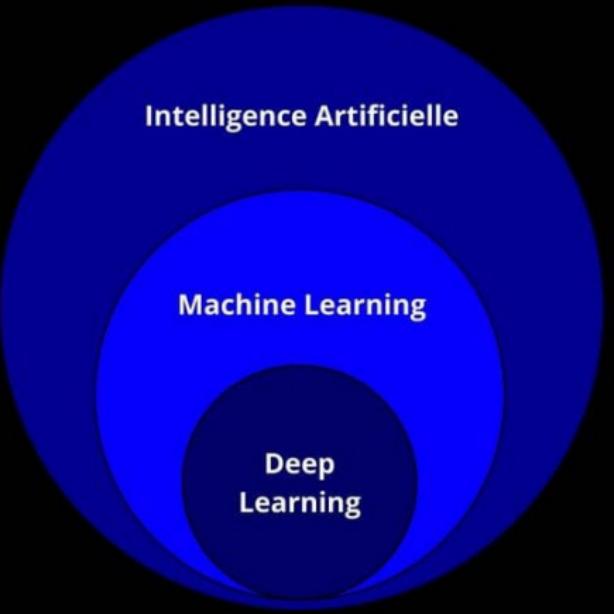
# Qu'est ce que le Machine Learning

C'est tout processus par lequel un système améliore ses performances à partir de l'expérience issue des données.

www.sales-hacking.com

## Intelligence Artificielle

Une science qui vise à faire en sorte que les machines pensent et agissent comme des humains.



Intelligence Artificielle

## Machine Learning

L'objectif est de permettre aux ordinateurs d'effectuer des tâches sans programmation explicite.

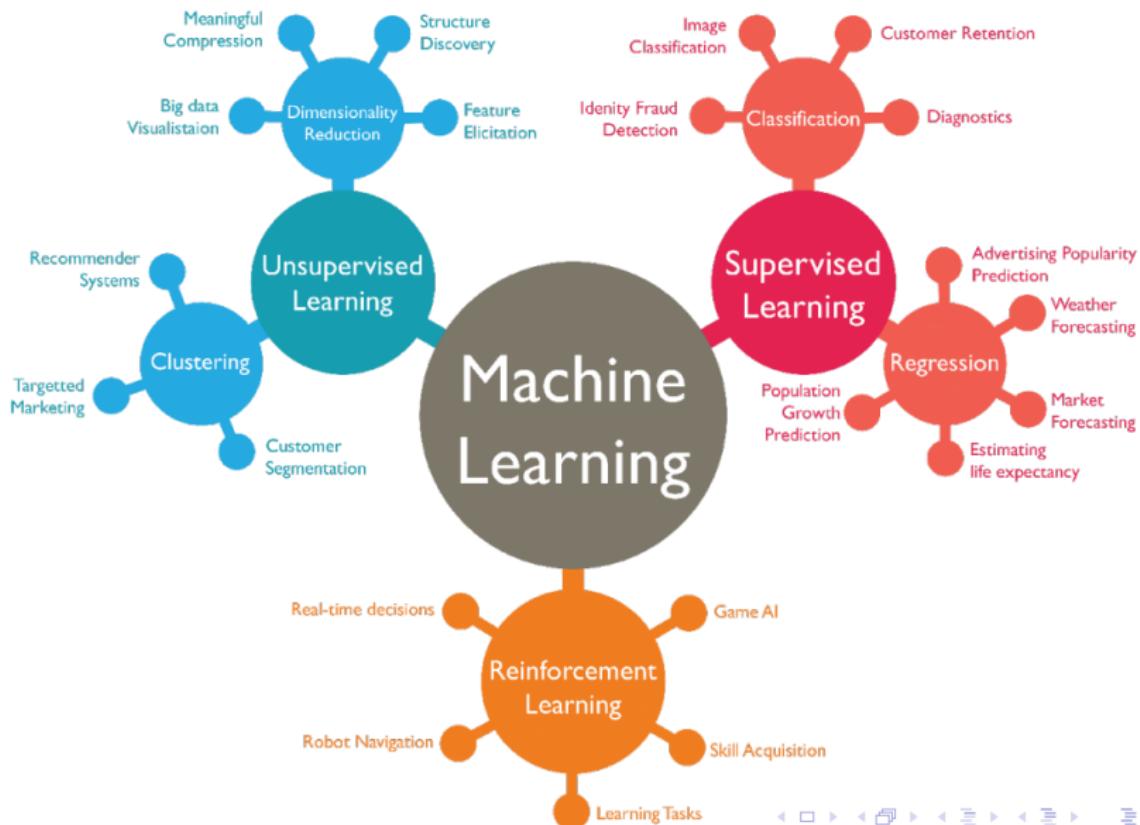
Machine Learning

## Deep Learning

Un sous-ensemble du Machine Learning basé sur les réseaux neuronaux.

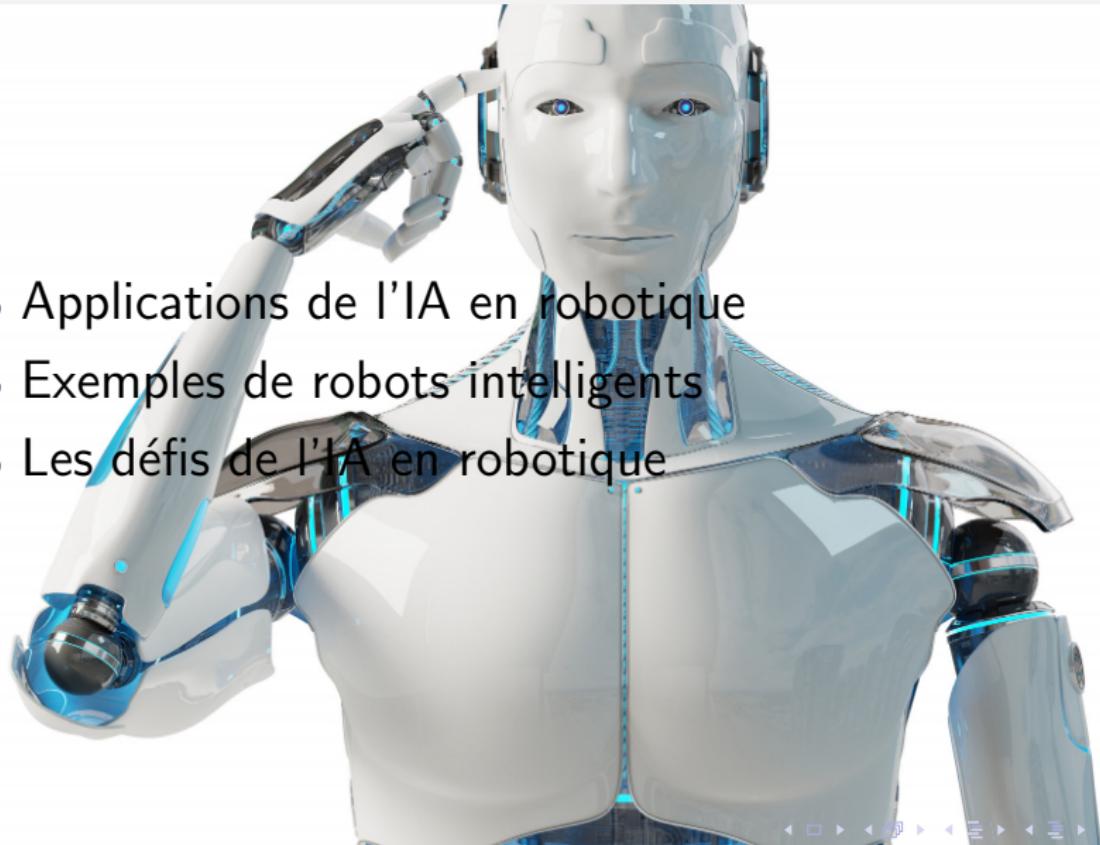
Deep  
Learning

# Approches techniques de l'IA utilisées dans le ML



# L'IA en robotique

- Applications de l'IA en robotique
- Exemples de robots intelligents
- Les défis de l'IA en robotique



# Applications de l'IA en robotique

- Industrie : robot de gestion de chaîne d'assemblage...
- Armée : drone, robot-espion, robot-mule...
- Sécurité : vidéosurveillance...
- Santé : échographie, chirurgie assistée...
- Aérospatial : robot explorateur de la NASA...
- Transport : voiture autonome...
- Usage domestique : robot aspirateur, robot tondeuse...
- Accompagnement : jouet automatisé, robot humanoïde...
- Informatique : chatbot, assistant vocal...

# Exemples de Robots intelligents

- Atlas : Robot humanoïde développé par Boston Dynamics, connu pour sa mobilité et sa dextérité avancées.
- Asimo : Robot humanoïde développé par Honda, célèbre pour sa marche bipède, sa capacité à monter les escaliers et ses mouvements semblables à ceux d'un humain.
- iCub : Robot humanoïde à source ouverte conçu pour étudier la cognition et le développement humains.
- Nao : Petit robot humanoïde créé par SoftBank Robotics, utilisé dans l'éducation, la recherche et le divertissement, capable d'interagir avec les humains par la parole et les gestes.





# Le Big Data et son intégration avec l'IA

- Les Big Data sont les traces numériques (données) qui se génèrent dans l'ensemble de l'écosystème numérique.
- Les Big Data sont des actifs d'information à haut volume, haute vélocité et haute variété.
- Les principales caractéristiques des Big Data sont les quatre V

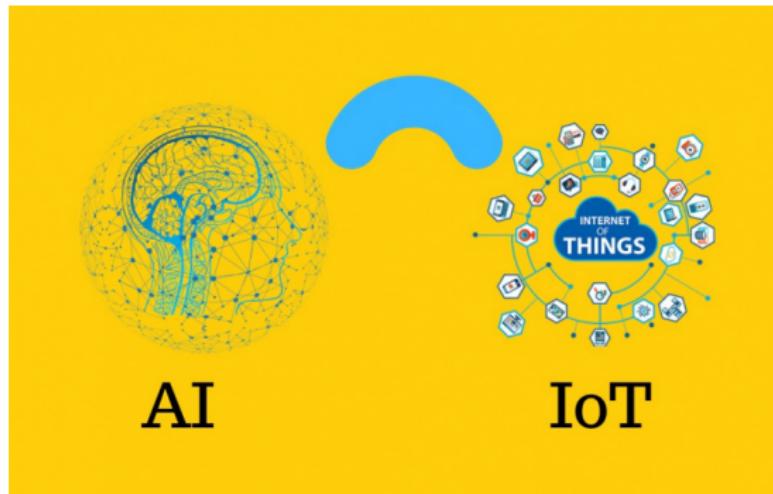


# Impact des Big Data

- Les appareils IoT génèrent continuellement d'énormes volumes de données.
- L'analyse des Big Data aide les entreprises à obtenir des informations à partir des données collectées par les appareils IoT.

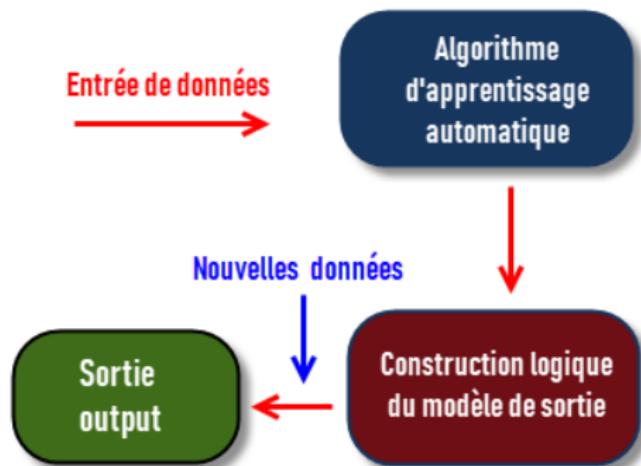


# Comment le Big Data alimente l'IA?



- Entraînement des modèles d'IA
- Amélioration de la précision
- Apprentissage en continu
- Détection des tendances et des modèles
- Personnalisation et recommandations

# Principe du Machine Learning



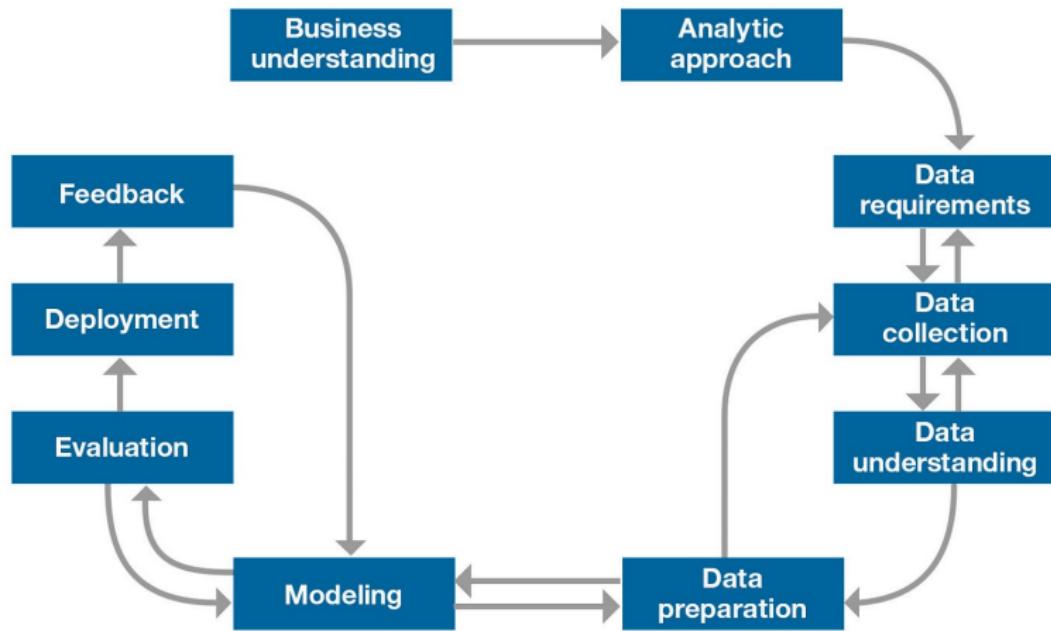
1. Les influences majeures du ML
2. Approche méthodologique du ML
3. Types d'apprentissage statistique
4. Travailler avec les données et éviter les pièges
5. Quelques modèles de ML

# Les influences majeures du ML

Le Machine learning ou apprentissage statistique est un champ d'étude de l'IA qui se fonde sur des approches statistiques pour donner aux ordinateurs la capacité d'apprendre à partir de données.

- ① La théorie formelle de la statistique
- ② L'accélération du développement des ordinateurs
- ③ Le défi, dans de nombreux domaines, de corpus de données toujours plus grands
- ④ L'accent mis sur la quantification dans une variété toujours plus large de disciplines

# Resumé de la méthodologie



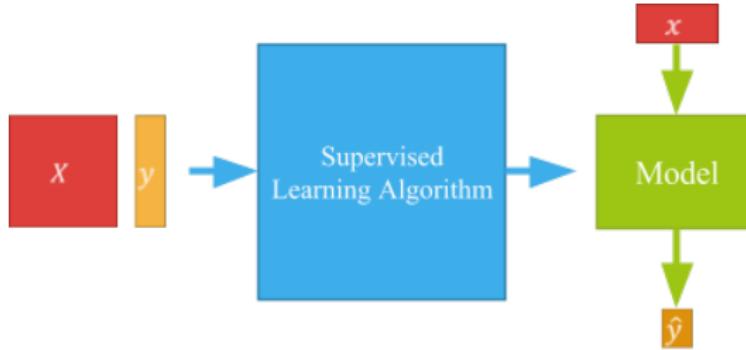
# Supervisé et non-supervisé

- Apprentissage supervisé

- Objectif : apprendre une fonction  $f$  prédisant une variable  $Y$  à partir de features  $X$ .
- Données : ensemble d'apprentissage  $(X_i, Y_i)$

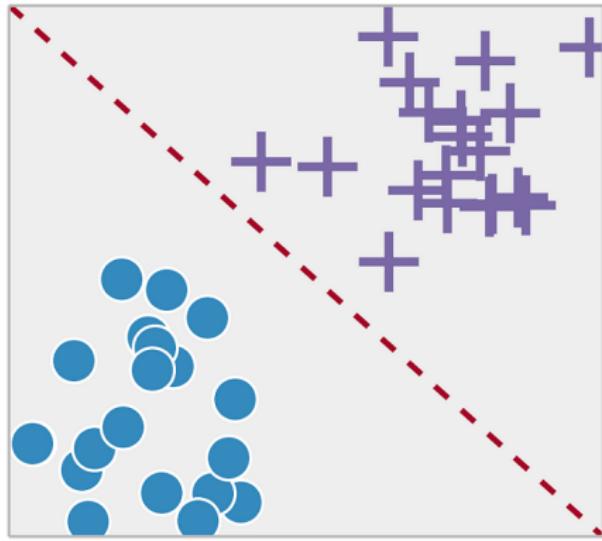
- Apprentissage non-supervisé

- Objectif: découvrir une structure au sein d'un ensemble d'individus ( $X_i$ )
- Data : Learning set ( $X_i$ )

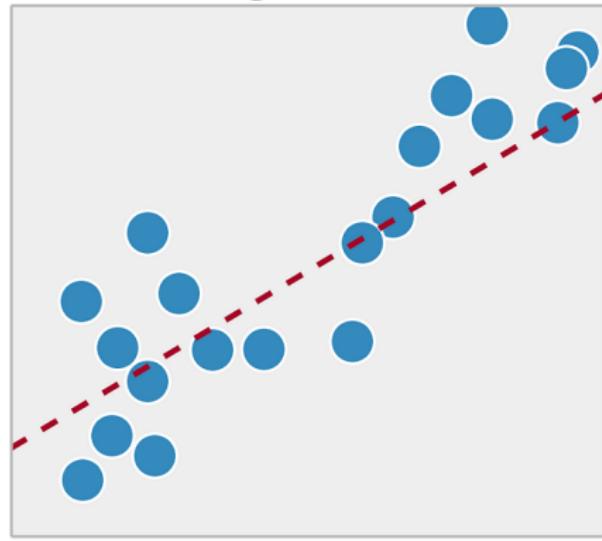


# Apprentissage supervisé

Classification



Regression



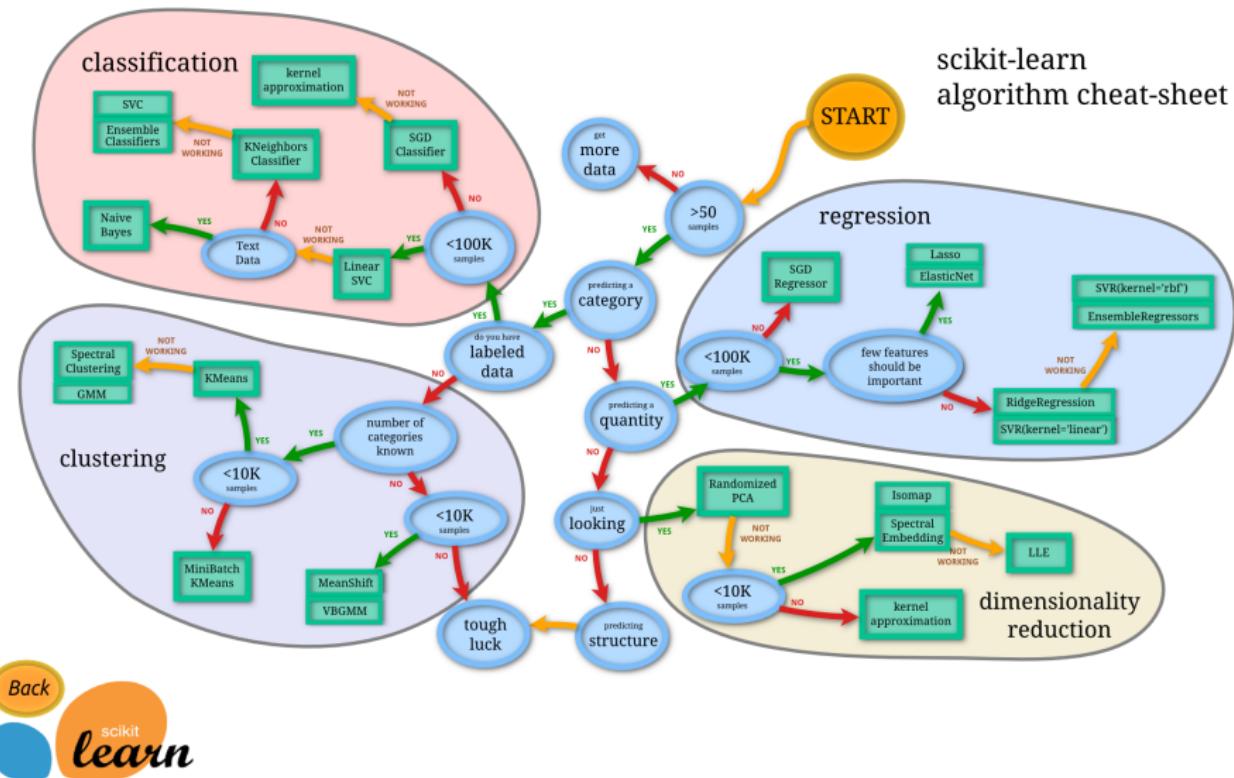


Figure: Grand catalogue de méthodes de ML

# Quiz: Classification ou Regression?

- 1 Vous avez un large inventaire d'articles identiques. Vous voulez prédire combien de ces articles se vendront au cours des 3 prochains mois.
- 2 Vous devez examiner les comptes de vos clients et décider pour chacun d'entre eux s'ils ont été piratés ou compromis.
- 3 Prédiction du churn d'une entreprise
- 4 Prédire si un prospect deviendra client
- 5 Prédire le chiffre d'affaire d'une entreprise dans 10 ans

# Quiz

**Given a case study: pricing apartments based on a real estate website.**

- House descriptions with their price
- Predicting house prices from their description
- Use case: finding houses that are cheap compared to market value

# Question 1

**What kind of problem is it?**

- a) A supervised problem
- b) An unsupervised problem
- c) A classification problem
- d) A regression problem

**Select all answers that apply**

## Question 2

**What are the features?**

- a) The number of rooms might be a feature
- b) The post code of the house might be a feature
- c) The price of the house might be a feature

**Select all answers that apply**

## Question 3

**What is the target variable?**

- a) The full text description is the target
- b) The price of the house is the target
- c) Only house descriptions with no price mentioned are the target

**Select a single answer**

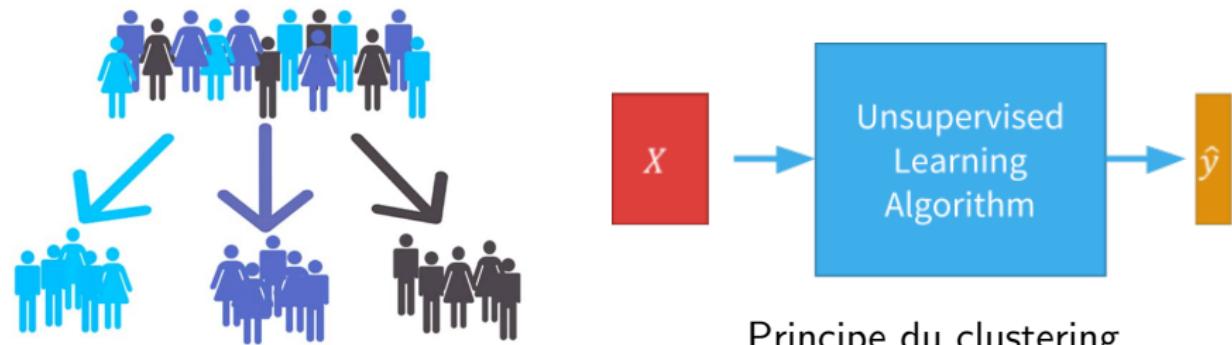
## Question 4

**What is a record (a sample, instance)? (observation)**

- a) Each house description is a record
- b) Each house price is a record
- c) Each kind of description (e.g., house size) is a record

**Select a single answer**

# Apprentissage non-supervisé (clustering)



3 Clusters

# Reduction de la dimension



Figure: Recommendation

# Réduction de la Dimensionnalité

- Technique utilisée pour réduire le nombre de features d'un dataset.
- Objectifs de la réduction de la dimensionnalité :
  - Réduire la complexité du modèle et le temps de calcul.
  - Éliminer les redondances et le bruit dans les données.
  - Visualiser les données dans un espace de dimension inférieure.
- Méthodes courantes de réduction de la dimensionnalité :
  - Analyse en composantes principales (PCA) : transforme les variables d'origine en un nouvel ensemble de variables non corrélées appelées CP.
  - Sélection de caractéristiques : sélectionne un sous-ensemble de caractéristiques les plus informatives.
  - Manifold Learning : trouve des représentations non linéaires des données dans un espace de dimension inférieure.

# Travailler avec les données et éviter les pièges

## Collecte et préparation des données

- ① Collecte des données de qualité et représentatives
  - Déterminez les informations que vous voulez collecter
  - Définissez la méthode de collecte des données
- ② Exploration des données (Data mining)
  - Compréhension du problème (activité, objectif)
  - Compréhension des données
- ③ Nettoyage des données
  - Gestion des erreurs de saisie
  - Gestion des doublons
  - Gestion des valeurs manquantes et des données aberrantes
- ④ Les bonnes pratiques de normalisation et transformation des données

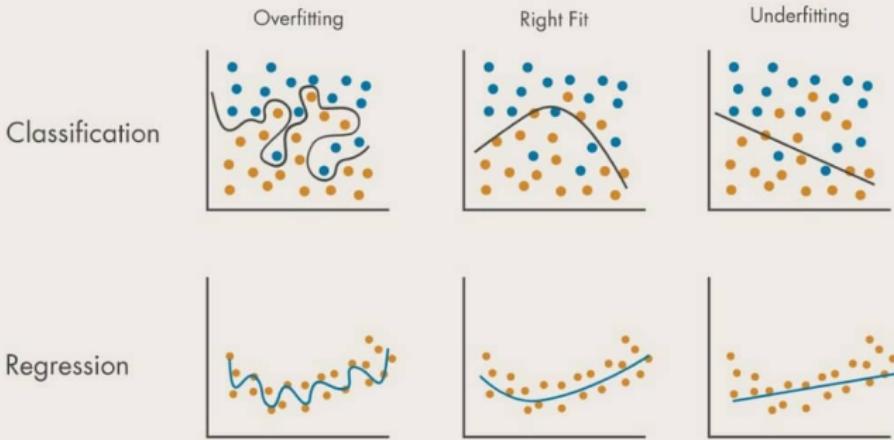
# Travailler avec les données et éviter les pièges

## Sélection des caractéristiques et modélisation

- ① Feature selection (features pertinentes pour le modèle)
- ② Choix et évaluation des modèles
  - Sélection du modèle approprié en fonction du problème et des data
  - L'utilisation de la validation croisée pour évaluer le modèle
  - L'interprétation des métriques d'évaluation telles que la précision, le rappel, le F1-score, etc.
- ③ Gestion du déséquilibre des classes
  - L'identification et la gestion du déséquilibre des classes dans les problèmes de classification
  - L'utilisation de techniques de suréchantillonnage, de sous-échantillonnage ou d'ajustement des poids des classes pour traiter ce déséquilibre

# Travailler avec les données et éviter les pièges

## Underfitting and Overfitting



### Réduction de l'overfitting

- La compréhension de l'overfitting et ses conséquences
- L'utilisation de techniques telles que la régularisation, la validation

# Quelques modèles de Machine Learning



# Modèles de Régression

## Régression Linéaire

Modélisation: relation entre les variables explicatives et la variable cible

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$$

- $y$  : Variable dépendante à prédire
- $x_1, x_2, \dots, x_n$  : Variables indépendantes (caractéristiques)
- $\beta_0, \beta_1, \beta_2, \dots, \beta_n$  : Coefficients de régression à estimer
- $\epsilon$  : Terme d'erreur aléatoire

## Régression Logistique

$$P(y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}$$

- $P(y = 1)$  : Probabilité que la variable dépendante  $y$  prenne la valeur 1
- $x_1, x_2, \dots, x_n$  : features.

# Arbre de Décision

- Modèle d'apprentissage automatique non linéaire et non paramétrique
- Représente une série de décisions basées sur les features
- Utilisé pour la classification et la régression

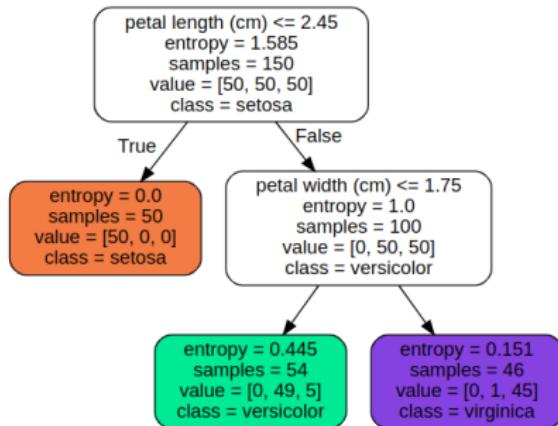


Figure: Classification tree

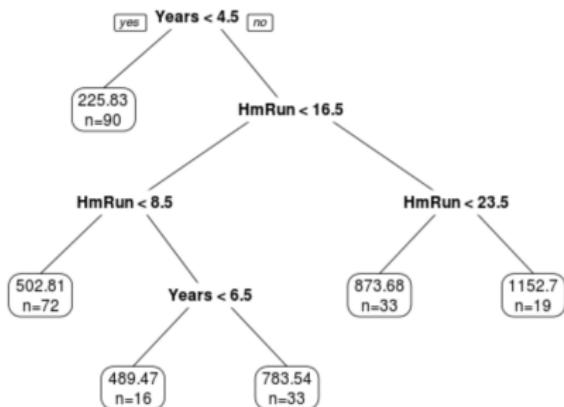


Figure: Regression tree

# Machines à Vecteurs de Support (SVM)

- Modèle d'apprentissage automatique supervisé
- Utilisé pour la classification et la régression
- Trouve un hyperplan optimal qui sépare les données de différentes classes ou estime une fonction pour la régression
- Maximise la marge entre les données et l'hyperplan pour une meilleure généralisation

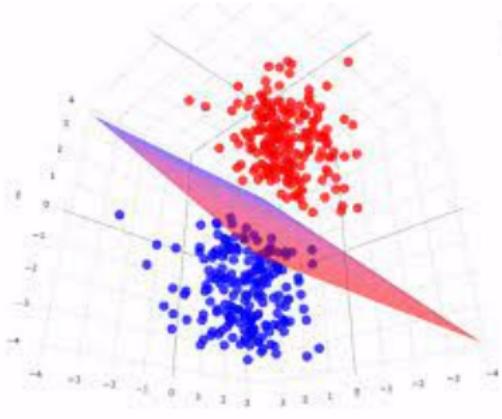


Figure: Support Vector Classifier

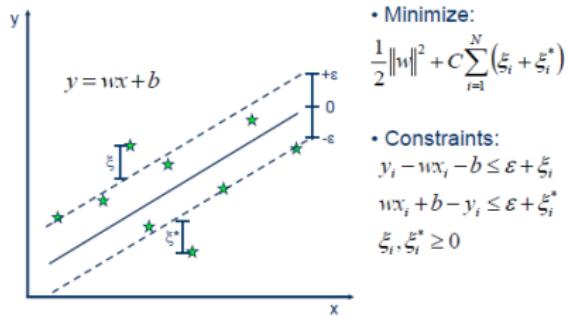
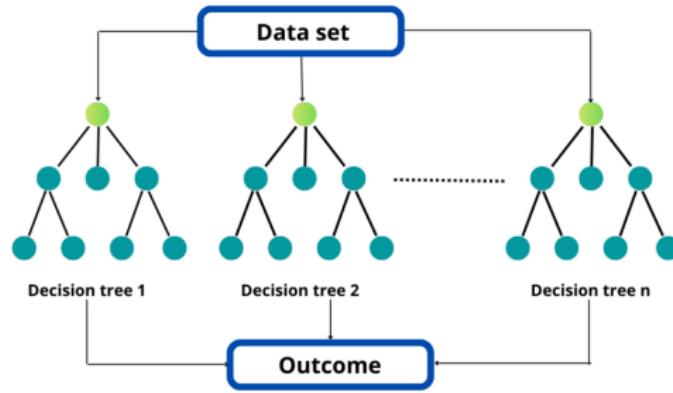


Figure: Support Vector Régresseur

# Forêt Aléatoire (Random Forest)

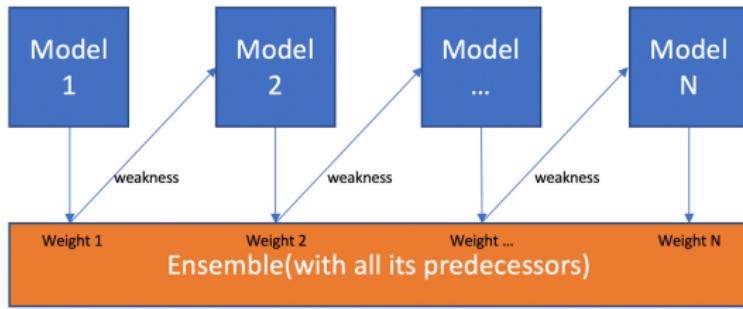
- Basée sur l'ensemble de plusieurs arbres de décision
- Chaque arbre est construit sur un sous-ensemble aléatoire des données d'entraînement et des caractéristiques
- Les prédictions finales sont obtenues en agrégant les prédictions de chaque arbre (majorité pour la classification, moyenne pour la régression)



# Boosting

- Technique de ML utilisée pour améliorer la performance des modèles
- Combinaison **séquentielle** de modèles faibles pour former un fort
- Chaque modèle faible est entraîné à se concentrer sur les échantillons mal classés par les modèles précédents
- Les prédictions finales sont obtenues en agrégant les prédictions de chaque modèle faible (pondération selon leur performance)

Model 1,2,..., N are individual models (e.g. decision tree)



# Boosting vs Bagging

## Boosting

- Combinaison séquentielle de modèles faibles
- Chaque modèle se concentre sur les échantillons mal classés par les modèles précédents
- Biais réduit, forte capacité de généralisation
- Sensible aux données d'entraînement bruitées ou aberrantes

## Bagging

- Combinaison parallèle de modèles indépendants
- Chaque modèle est entraîné sur un sous-ensemble aléatoire des données d'entraînement
- Réduction de la variance, faible risque de surajustement
- Moins sensible aux données bruitées ou aberrantes

# Évaluation des modèles

- L'évaluation des modèles est essentielle pour mesurer leur performance et prendre des décisions informées.
- Métriques de performance couramment utilisées :
  - Précision : mesure la proportion de prédictions positives correctes.
  - Rappel : mesure la proportion de vrais positifs identifiés.
  - F-mesure : combine la précision et le rappel en une seule métrique.
  - Exactitude : mesure la proportion de prédictions correctes dans l'ensemble des données.
  - Courbe ROC : représente la sensibilité (rappel) en fonction de la spécificité.
- Techniques d'évaluation :
  - Validation croisée : divise les données en ensembles d'entraînement et de test pour évaluer la performance.
  - Holdout : divise les données en un ensemble d'entraînement et un ensemble de test.
  - Bootstrap : utilise des échantillons bootstrap pour estimer la performance du modèle.

# Conclusion

- Le Machine Learning est une approche d'intelligence artificielle qui permet aux ordinateurs d'apprendre à partir des données sans être explicitement programmés.
- Le processus de Machine Learning comprend :
  - ① Collecte des données d'entraînement.
  - ② Sélection du modèle approprié.
  - ③ Entraînement du modèle sur les données d'entraînement.
  - ④ Évaluation de la performance du modèle sur des données de test.
  - ⑤ Utilisation du modèle entraîné pour faire des prédictions sur de nouvelles données.
- Les algorithmes d'apprentissage automatique peuvent être supervisés ou non supervisés.
- L'objectif du Machine Learning est de généraliser à partir des données d'entraînement afin de faire des prédictions précises sur de nouvelles données non vues auparavant.

# Artificial Intelligence and Machine Learning 2



AI / ML

# Plan de présentation

- Introduction
  - Contexte et objectifs
- XAI et IML : Explicabilité dans l'IA et le ML
  - Comprendre XAI et IML
  - Difficultés liées à l'isolation de la contribution d'une variable
  - Modèle de boîte noire 101
- KNIME pour XAI et IML
  - Présentation de KNIME
  - Utilisation de KNIME pour l'explicabilité et l'interprétabilité
  - Exemples d'utilisation de KNIME dans XAI et IML
- Techniques de XAI : Explications globales
  - Obtenir des explications globales
  - Techniques : importance des variables, arbres de décision, règles d'association, etc.
  - Avantages et limitations des techniques d'explication globale

# Vue d'ensemble des concepts clés

- Qu'est-ce que l'Explainable AI (XAI) et l'Interprétabilité en ML (IML)?
- Les défis de l'isolement de la contribution d'une variable
- Modèle de boîte noire 101 : Comprendre les modèles opaques
- KNIME pour XAI et IML : Une introduction à l'outil
- Techniques d'Explainable AI (XAI) : explications globales, explications locales
- Techniques d'Interprétabilité en Machine Learning (IML) : visualisation, importance des variables, etc.
- Conception expérimentale et contrôles statistiques : l'importance de la planification et des comparaisons de modèles
- Conditionnel Probabilité et théorème de Bayes : Mise à jour des probabilités
- Prédiction et preuve avec les statistiques bayésiennes : Introduction aux statistiques bayésiennes
- Modélisation causale : Modélisation d'équations structurelles (SEM), 

# Explainable AI (XAI) et Interprétabilité en ML (IML)

- L'Explainable AI (XAI) et l'Interprétabilité en ML (IML) visent à rendre les modèles de ML plus compréhensibles et expliquables pour les humains.
- L'IML : compréhension des décisions prises par les modèles, alors que le XAI vise à expliquer le fonctionnement interne des modèles.
- L'importance de l'IML et du XAI :
  - Gagner la confiance des utilisateurs et des parties prenantes.
  - Déetecter les biais et les erreurs de modélisation.
  - Se conformer aux réglementations et aux normes éthiques.
  - Faciliter la résolution des problèmes lorsque les modèles produisent des résultats inattendus ou incorrects.
- Techniques d'IML et de XAI :
  - Visualisation des caractéristiques importantes.
  - Interprétation des poids des modèles linéaires.
  - Méthodes d'interprétabilité spécifiques à certains algorithmes (des tree).
  - Utilisation de modèles explicatifs, tels que les réseaux de neurones à propagation avant avec des couches interprétables.

# Les défis de l'isolement de la contribution d'une variable

- Les défis courants de l'isolation de la contribution d'une va en ML :
  - Corrélations
  - Interactions
  - Non-linéarité : les relations entre les variables et la variable cible peuvent être non linéaires, ce qui complique l'isolement des contributions individuelles.
  - Multicollinéarité
- Méthodes pour aborder ces défis :
  - Analyse de sensibilité : évaluer l'impact d'une variable en la modifiant de manière contrôlée tout en maintenant les autres variables constantes.
  - Décomposition de la variance : attribuer une part de la variance expliquée à chaque variable.
  - Méthodes d'importance de variable : estimer l'importance relative des variables en utilisant des techniques telles que les arbres de décision ou les coefficients de régression.

# Modèle de boîte noire 101 : Modèles opaques



- Modèles d'IA dont les mécanismes internes sont difficiles à interpréter.
- Modèles très performants en termes de prédiction, mais souvent difficile à comprendre.
- Les modèles opaques (DNN ou SVM) peuvent avoir des millions de paramètres et des architectures complexes.
- L'opacité de ces modèles pose des défis en termes de transparence, d'éthique et d'acceptabilité sociale de l'IA.
- Malgré leur complexité, XAI et IML tentent de les comprendre.

# KNIME pour XAI et IML : Une introduction à l'outil

- KNIME est une plateforme open-source d'analyse des données et de construction de workflows.
- Il offre une interface intuitive et conviviale pour créer, exécuter et partager des workflows d'analyse de données.
- KNIME propose également une large gamme de modules et d'extensions pour XAI et l'IML.
- Avec KNIME, vous pouvez appliquer des techniques d'XAI pour comprendre comment les modèles prennent des décisions et les expliquer de manière compréhensible.
- Vous pouvez également utiliser des modules d'IML pour visualiser et interpréter les résultats de vos modèles, tels que l'importance des variables, les poids des coefficients, etc.
- KNIME offre une flexibilité et une extensibilité importantes, vous permettant d'adapter facilement vos workflows aux besoins spécifiques de votre projet.

# Techniques XAI : explications globales, explications locales

- Les techniques XAI sont des méthodes utilisées pour expliquer les décisions prises par les modèles d'IA.
- Les explications globales fournissent une vue d'ensemble du modèle et de ses principaux facteurs de décision, permettant de comprendre le comportement général du modèle.
- Les techniques d'explication globale incluent des méthodes telles que les diagrammes d'importance de variables, les graphiques de dépendance partielle et les cartes de chaleur.
- Les explications locales se concentrent sur une prédition spécifique et fournissent une explication détaillée de la contribution de chaque variable à cette prédition.
- Les techniques d'explication locale incluent des méthodes telles que les perturbations de variable, les méthodes de désensibilisation et les arbres de décision locaux.
- Compréhension fine des facteurs qui ont conduit à une prédition spécifique, ce qui peut aider à détecter les biais, les erreurs ou les cas

# Techniques IML : visualisation, importance des variables

- La visualisation permet d'explorer et de comprendre les relations entre les variables et les résultats du modèle.
- Les graphiques, les diagrammes et les cartes peuvent être utilisés pour représenter les données de manière intuitive et faciliter l'interprétation.
- L'importance des variables est une autre technique d'IML qui permet d'identifier les variables qui ont le plus d'influence sur les prédictions du modèle.
- Les méthodes d'importance des variables incluent l'analyse de sensibilité, le calcul des coefficients ou des poids des variables et les techniques d'élagage.
- En combinant la visualisation des données, l'importance des variables et d'autres techniques d'IML, on peut obtenir une compréhension approfondie du modèle de ML et de ses mécanismes de décision.

# Conception expérimentale et contrôles statistiques

- Planification : définition claire des objectifs de l'expérience, choix des features à mesurer, échantillonnage.
- Les comparaisons de modèles
- Des techniques statistiques telles que les tests d'hypothèse, l'ANOVA et les tests de comparaison multiple
- Il est également important de prendre en compte les biais potentiels
- Une planification et des contrôles appropriés permettent de minimiser les erreurs expérimentales, d'obtenir des résultats précis et de fournir des informations utiles pour prendre des décisions éclairées en matière de modélisation.
- En fin de compte, la conception expérimentale et les contrôles statistiques renforcent la validité et la crédibilité des résultats obtenus à partir des modèles d'IA.

# Probabilité Conditionnelle et théorème de Bayes

- Elle est notée  $P(A|B)$  et se calcule suivant la relation

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- Le théorème de Bayes permet de mettre à jour les probabilités conditionnelles lorsque de nouvelles informations sont disponibles.
- La formule de Bayes est donnée par

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

- Le théorème de Bayes est largement utilisé dans les domaines de la statistique, du ML et de l'IA pour la prise de décision.
- Il permet de mettre à jour les probabilités a priori en fonction des nouvelles observations, ce qui permet d'obtenir des estimations plus précises et fiables.

# Introduction aux statistiques bayésiennes

- Contrairement aux statistiques fréquentistes, les statistiques bayésiennes considèrent les paramètres comme des v.a avec des dp.
- L'analyse bayésienne commence par une distribution a priori pour les paramètres, puis met à jour cette distribution en utilisant le théorème de Bayes pour obtenir une distribution a posteriori.
- La distribution a posteriori est utilisée pour effectuer des prédictions et des estimations, en tenant compte de l'incertitude associée aux résultats.
- Les statistiques bayésiennes permettent également de comparer des modèles en utilisant des facteurs de Bayes, qui intègrent la vraisemblance des données et la complexité des modèles.
- Les statistiques bayésiennes offrent une approche cohérente et intuitive pour la prise de décision en intégrant les connaissances préalables et les données observées.
- Cependant, l'analyse bayésienne peut nécessiter des techniques d'inférence approximative, telles que les chaînes de Markov Monte Carlo.

# Modélisation causale : Modélisation d'équations structurelles (SEM), réseaux bayésiens

- La modélisation causale vise à comprendre les relations de cause à effet entre les variables dans un système.
- Les équations structurelles (SEM) et les réseaux bayésiens sont deux approches couramment utilisées en modélisation causale.
- Les SEM sont des modèles qui représentent les relations causales entre les variables à l'aide d'équations mathématiques.
- Les SEM permettent de tester des hypothèses causales.
- Les réseaux bayésiens, quant à eux, utilisent des graphes probabilistes pour représenter les relations causales entre les variables.
- Les réseaux bayésiens intègrent également des connaissances a priori et des distributions de probabilité pour quantifier l'incertitude dans la modélisation causale.
- Ces approches permettent de faire des prédictions causales, d'identifier les variables clés et de tester les hypothèses causales.



# Statistiques et tests d'hypothèse

- La  $p$ -value est utilisée pour évaluer les preuves contre l'hypothèse  $H_0$ .
- Une  $p$ -value faible indique une preuve solide contre  $H_0$ .
- La  $p$ -value seule ne fournit pas d'informations sur la taille de l'effet ou la signification pratique des résultats.
- L'interprétation doit tenir compte de la  $p$ -value et de l'importance clinique ou scientifique des résultats.
- La corrélation mesure la relation statistique entre deux variables.
- La causalité nécessite des preuves supplémentaires, comme des expérimentations contrôlées.
- Les études observationnelles fournissent des indications de relation causale, mais ne prouvent pas définitivement l'existence de la causalité.

# Détection de la multicolinéarité et stratégies associées

## Détection de la multicolinéarité :

- Calcul des coefficients de corrélation.
- Variance inflation factor (VIF).
- Analyse des valeurs propres.

## Stratégies pour traiter la multicolinéarité :

- Supprimer les variables fortement corrélées.
- Combinaison de variables corrélées.
- Utilisation de techniques de régularisation (régression ridge, régression lasso).

**Remarque :** Les approches de détection et de gestion de la multicolinéarité doivent être adaptées au contexte spécifique de l'analyse et aux objectifs de modélisation.

# Induction, déduction, falsification et contrefactuel : Importance dans l'évaluation du modèle

- **Induction** : Permet de généraliser à partir des observations spécifiques et de tirer des conclusions sur des situations non observées.
- **Déduction** : Utilisation de règles logiques pour déduire des conséquences spécifiques à partir de propositions générales. Peut aider à tester les prédictions d'un modèle.
- **Falsification** : Processus de recherche d'observations ou de tests qui pourraient réfuter ou invalider un modèle. Contribue à la rigueur et à la fiabilité d'un modèle.
- **Contrefactuel** : Étudie les effets hypothétiques d'un changement dans les conditions ou les variables. Permet d'évaluer l'impact causal et de comparer différentes situations.

L'utilisation appropriée de ces concepts contribue à une évaluation rigoureuse et solide des modèles, en tenant compte à la fois des preuves empiriques et des raisonnements logiques.

# Utilité décroissante des valeurs p avec un nombre croissant de paramètres de modèle : Explication

- Lorsque le nombre de paramètres d'un modèle statistique augmente, les valeurs p associées à ces paramètres ont tendance à diminuer.
- Les valeurs p mesurent la significativité statistique d'un paramètre en évaluant la probabilité d'obtenir des résultats aussi extrêmes que ceux observés, sous l'hypothèse nulle.
- Cependant, avec un nombre croissant de paramètres, il y a une augmentation du nombre de tests statistiques effectués, ce qui peut conduire à une augmentation des chances de trouver des associations significatives par pur hasard.
- Ce phénomène est connu sous le nom d'utilité décroissante des valeurs p et est causé par le problème de multiplicité des tests.
- Plus il y a de paramètres à tester, plus il est probable d'obtenir des associations significatives par simple hasard, même en l'absence de relations réelles entre les variables.
- Cela souligne l'importance de prendre en compte le contexte

# Évaluation des performances du modèle dans l'EDA

- L'évaluation des performances du modèle est une étape essentielle dans l'exploration de données, visant à évaluer la qualité et l'adéquation d'un modèle pour représenter les données.
- Les statistiques et l'exploration de données ont des objectifs et des philosophies souvent contradictoires dans cette évaluation.
- Les statistiques traditionnelles se concentrent sur la précision et la validité des modèles, en utilisant des méthodes rigoureuses basées sur des hypothèses et des tests statistiques.
- Les statistiques mettent l'accent sur la généralisation des résultats, la réduction de l'incertitude et la déduction causale.
- En revanche, l'exploration de données se concentre sur la découverte de nouvelles connaissances, l'identification de modèles intéressants et la génération d'hypothèses.
- L'exploration de données privilégie l'exploration des données brutes, l'utilisation de techniques non paramétriques et l'incorporation de l'expertise humaine.

# Conclusion

- Récapitulatif des concepts clés abordés dans les applications pratiques de l'IA et du Machine Learning
- Invitation aux questions et discussions

# Artificial Intelligence and Machine Learning 3



AI / ML

# Plan de présentation

- Examen des défis de l'IA
- Application de l'IA étroite à une décision
- Définition de deux approches efficaces utilisées face à l'IA
- Examen de l'apprentissage supervisé et non supervisé
- Explication du harcèlement par l'IA
- Identification de trois concepts sur lesquels repose la justice distributive
- Qu'est-ce que XAI (IA explicative) ?
- Avantages et limites de XAI
- Humains par rapport aux ordinateurs
- Exemples commerciaux de XAI
- Investir dans XAI
- Transformateurs en PNL
- Formation des transformateurs et leur architecture
- Grands modèles de langage
- Présentation des arbres de décision

# Examen des défis de l'IA

- Manque de transparence des modèles d'IA
- Biais et résultats discriminatoires
- Problèmes d'éthique et de confidentialité
- Impact sur l'emploi
- Besoin de big data
- Sécurité des systèmes d'IA



# Définition de deux approches efficaces utilisées face à l'IA

## Apprentissage supervisé

- Utilise des données étiquetées
- Prédit des résultats pour de nouvelles données
- Exemples : classification, prédiction

## Apprentissage non supervisé

- Utilise des données non étiquetées
- Découvre des structures, des modèles ou des relations
- Exemples : regroupement, réduction de dimensionnalité

Supervised Learning

X <sub>1</sub>	X <sub>2</sub>	X <sub>3</sub>	X <sub>p</sub>	Y

Un-Supervised Learning

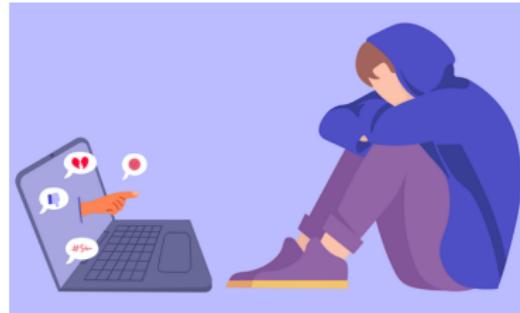
X <sub>1</sub>	X <sub>2</sub>	X <sub>3</sub>	X <sub>p</sub>	Y

# Application de l'IA étroite à une décision

- L'IA étroite ou IA faible, se réfère à des systèmes d'IA conçus pour effectuer des tâches spécifiques avec une grande précision.
- Ces systèmes d'IA sont utilisées en reconnaissance d'image, traduction automatique, détection de fraude, etc.
- L'IA étroite est utilisée dans les systèmes de recommandation personnalisée ou les chatbots de service client.
- Les systèmes d'IA étroite utilisent des algorithmes sophistiqués et des techniques de ML.
- Limites: incapacité à reproduire pleinement les capacités cognitives humaines (compréhension du contexte, de flexibilité et de raisonnement abstrait).

# Explication du harcèlement par l'IA

- Génération de contenu haineux
- Ciblage et traque en ligne
- Biais et discrimination



- Les modèles d'IA peuvent être exploités pour générer automatiquement du contenu haineux et offensant.
- Les algorithmes d'IA peuvent être utilisés pour cibler et harceler des individus en ligne.
- Les biais et préjugés présents dans les données d'entraînement peuvent conduire à une discrimination automatique.

# Concepts clés de la justice distributive

## Égalité

- Principe fondamental de la justice distributive
- Répartition équitable des ressources et des avantages
- Élimination de la discrimination basée sur des features personnelles

## Besoins

- Prise en compte des besoins réels des individus
- Attribution des ressources en fonction des besoins urgents ou essentiels
- Exemple : priorité d'accès aux soins pour les personnes malades

## Mérite

- Distribution des ressources en fonction du mérite ou de la contribution
- Récompense des gens pour leur travail, compétences ou contribution
- Exemple : rémunération plus élevée pour les compétences spécialisées ou les emplois valorisés

# XAI (IA explicative)

Rendre les décisions des IA explicables pour les utilisateurs humains.

- Avantages de XAI :
  - Compréhension des décisions des modèles d'IA.
  - Détection des biais et des erreurs dans les prédictions.
  - Renforcement de la confiance des utilisateurs dans les systèmes d'IA.
- Limites de XAI :
  - Certaines IA sont intrinsèquement opaques et difficiles à expliquer.
  - XAI peut ne pas refléter pleinement la complexité du modèle.
  - Explicabilité et performance des modèles délicat à atteindre.
- Exemples commerciaux de XAI :
  - Systèmes de recommandation personnalisée expliquant les suggestions.
  - Modèles d'IA pour la détection de fraude expliquant les classifications.
  - Chatbots explicatifs expliquant le raisonnement derrière leurs réponses.
- Importance d'investir dans XAI :
  - Renforcement de la transparence et de la responsabilité des IA.
  - Réduction des risques liés aux décisions automatisées.
  - Adoption plus large et acceptation sociale de l'IA.

# Transformateurs en PNL

## Architecture du transformateur

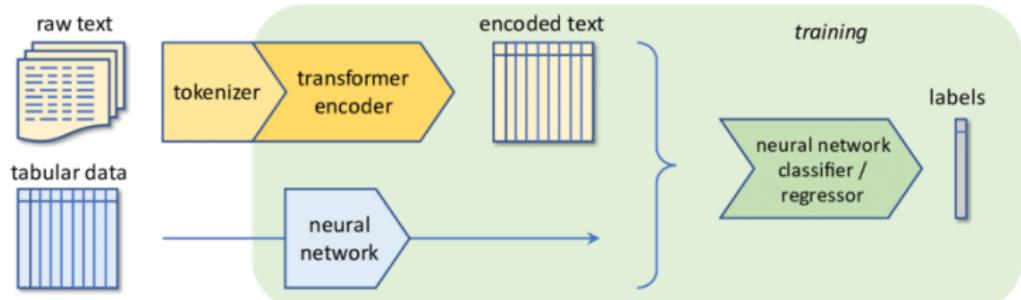
- Les couches d'attention capturent les relations entre les mots.
- Pas besoin de modèles récurrents ou de convolutions.

## Formation des transformateurs

- Apprentissage supervisé avec des tâches spécifiques.
- Entraînement sur de grandes quantités de données annotées.

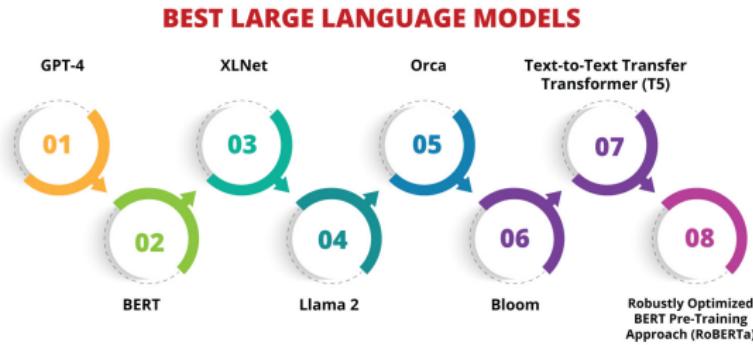
## Applications en PNL

- Traduction automatique
- Génération de texte et Compréhension du langage



# Grands modèles de langage

- Les grands modèles de langage révolutionnent le PNL.
- Basés sur les transformateurs, des architectures de réseaux np.
- GPT (Generative Pre-trained Transformer) : Apprentissage non supervisé, excellente génération de texte.
- BERT (Bidirectional Encoder Representations from Transformers) : Apprentissage supervisé, diverses tâches de PNL.
- T5 (Text-to-Text Transfer Transformer) : toutes les tâches de PNL.



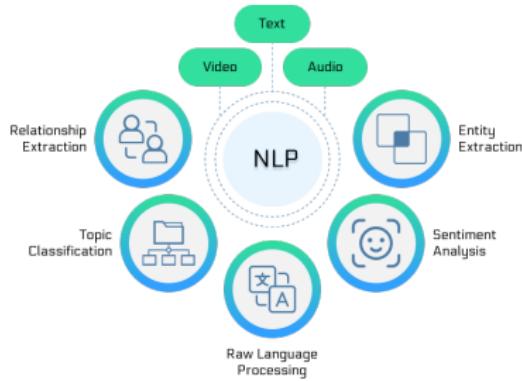
# NLP et transformateurs

## Traitement du langage naturel (NLP)

- IA qui se concentre sur l'interaction ordinateurs - langage h.
- Traduction, génération de texte, compréhension du langage

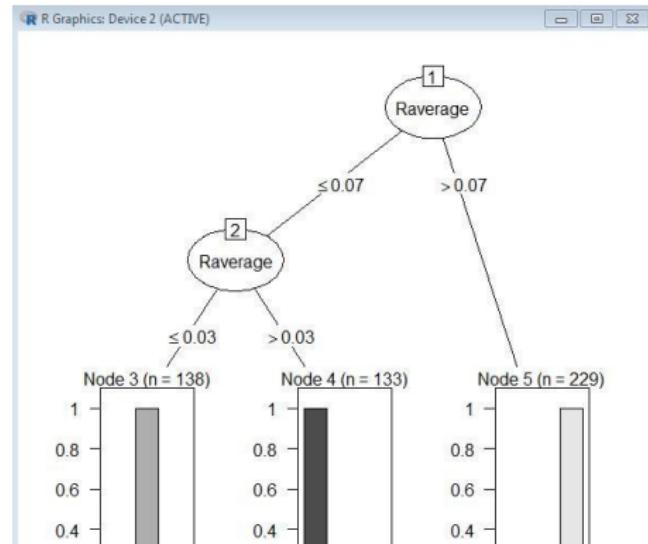
## Transformateurs

- Prise en compte des dépendances dans les séquences.
- Élimine le besoin de modèles récurrents ou de convolutions



# Présentation de l'algorithme C5.0

- Collecte des données étiquetées pour la classification.
- Construction d'un arbre de décision en sélectionnant la meilleure variable d'entrée à chaque nœud.
- Prédiction des classes pour les exemples non étiquetés.
- Élagage de l'arbre pour améliorer la généralisation.



# Artificial Intelligence and Machine Learning 4



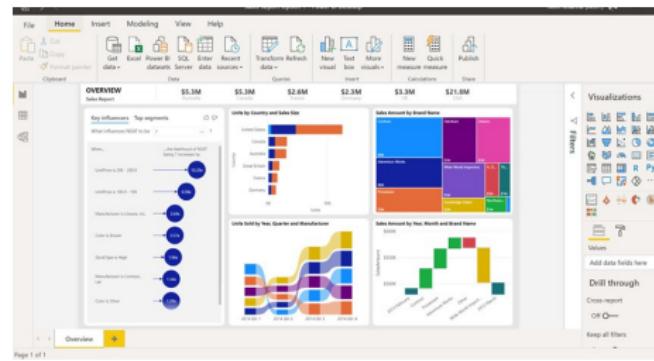
AI / ML

# Plan de présentation

- Power BI
  - Analyse d'une variable unique
  - Mesure des relations entre les variables
  - Utilisation de visuels d'IA pour poser des questions de simulation
  - Analyse de données de séries chronologiques
  - Création et partage d'analyses
- Chatbots avec Azure
  - Introduction aux chatbots
  - Terminologie et architecture des chatbots
  - Conception d'un chatbot et amélioration des actions
- Chatbots via Google Dialogflow
  - Blocs de construction Dialogflow
  - Configuration d'un compte Dialogflow
  - Création des intentions
  - Importation et exportation d'un agent
  - Création des entités et des paramètres
  - Ajout des intentions de suivi
  - Contexte d'entrée et de sortie

# Power BI : Business Intelligence pour tous

- Power BI, plateforme de BI développée par Microsoft.
- Importer, visualiser et analyser les data interactivement.
- Data Analyst, Responsable d'entreprise ou utilisateurs.
- Transformer et modéliser les data.
- Créer des tableaux de bord interactifs et attrayants pour partager vos analyses..



# Analyse d'une variable unique

- Une fois les données importées, vous pouvez effectuer des analyses sur une variable unique.
- Représenter graphiquement la distribution de la variable.
- Créer des histogrammes, diagrammes en boîte, des diagrammes à barres, etc.
- Ces visualisations vous aident à comprendre les tendances, les valeurs aberrantes et les diverses caractéristiques de la variable.

# Mesure des relations entre les variables

- Les diagrammes de dispersion (scatter plots).
- Analyse statistique (coefficients de corrélation) pour quantifier la force et la direction des relations entre les variables.
- Comprendre les dépendances entre les différentes variables et à identifier les facteurs qui influencent vos données.
- En explorant les relations entre les variables, vous pouvez prendre des décisions éclairées et développer des modèles prédictifs plus précis.

# Utilisation de visuels d'IA pour poser des questions de simulation

- Power BI intègre des fonctionnalités d'IA pour vous permettre de poser des questions de simulation à vos données.
- Vous pouvez utiliser des visuels d'IA, tels que les cartes de tendance temporelle prédictive, pour obtenir des prévisions et des simulations basées sur vos données historiques.
- Ces visuels vous aident à explorer différents scénarios et à évaluer l'impact de différentes variables sur vos résultats.
- Par exemple, vous pouvez simuler l'effet d'une augmentation des prix sur les ventes ou visualiser l'évolution attendue d'une métrique au fil du temps.
- En utilisant ces visuels d'IA, vous pouvez prendre des décisions plus éclairées et anticiper les résultats potentiels de vos actions.

# Modèle de série chronologique

## Qu'est-ce qu'une série chronologique ?

- Une série chronologique est une collection de données organisées selon un ordre temporel.
- Chaque observation est associée à une date ou un instant précis.
- Les séries chronologiques peuvent être univariées ou multivariées.

## Modélisation de séries chronologiques

- L'objectif de la modélisation de séries chronologiques est de comprendre les motifs, les tendances et les comportements dans les données temporelles.
- Les modèles de séries chronologiques utilisent des équations mathématiques pour décrire et prévoir les données.
- Les techniques de modélisation: ARIMA, modèles de lissage exponentiel, les réseaux de neurones récurrents (RNN) et les modèles basés sur les états cachés.

# Mise en œuvre de l'analyse de séries chronologiques avec Power BI

## Visualisation des séries chronologiques

- Importez vos données de séries chronologiques dans Power BI.
- Utilisez des visualisations appropriées pour afficher les tendances, les motifs saisonniers et les variations.

## Prévision des séries chronologiques

- Utilisez les équations mathématiques des modèles de séries chronologiques pour générer des prévisions.
- Les modèles ARIMA, par exemple, sont basés sur les équations AR (AutoRegressive), MA (Moving Average) et I (Integrated) pour capturer les motifs, les tendances et les erreurs.

## Analyse des séries chronologiques

- Utilisez les fonctions DAX pour calculs et analyses des séries chrono.
- Les moyennes mobiles, les décompositions saisonnières et les tests stat

# Python 1 : Initiation



python

# Plan de présentation

- Apprentissage automatique avec Python
- Collecte de données pour l'apprentissage automatique
- Compréhension des données pour l'apprentissage automatique
- Préparation des données pour l'apprentissage automatique
- Types de modèles d'apprentissage automatique
- Arbres de décision
- Compréhension du clustering K-Means
- Segmentation des données avec le clustering K-Means
- Règles d'association
- Découverte de modèles avec des règles d'association
- Réseaux de neurones en Python
- Choix d'un réseau de neurones
- Les éléments constitutifs des réseaux de neurones
- Construction de votre réseau
- Formation de votre réseau
- Création d'un affichage de segments classificateur

# Python



Plateforme de distribution des IDE et Librairies Python



Environnement Python



Travail collaboratif



Platform

IDE

Library

## Outils de développement - Code Python

### Matplotlib

Visualisation et affichage graphique



### Pandas

Manipulation de données

### NumPy

Manipulation de tableaux multidimensionnels

### Scikit-learn

Algorithme pour Machine Learning

### TensorFlow

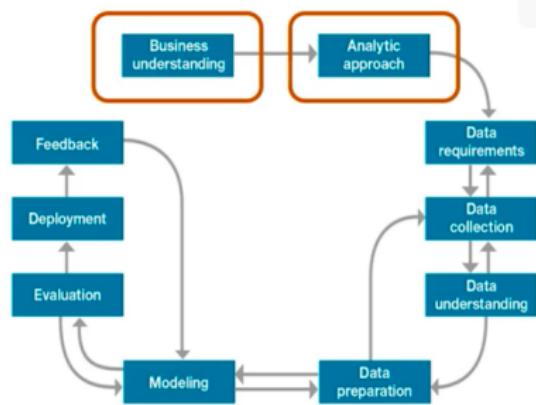
Machine Learning et CNN

#### Librairies

Appelées en début de programme pour utiliser des fonctions prédéfinies

# From Understanding to Approach

Supposons que nous souhaitons automatiser le processus de détermination de la cuisine d'un plat ou d'une recette donnée.



## Business understanding

- What is the problem that you are trying to solve?*



## Analytic approach

- How can you use data to answer the question?*

# Cuisines



Figure: Atayef and Ma'mul -  
Balha's Pastry



Figure: Avgolemono Soup and  
Grilled Chicken



Figure: Bacon and cheese



Figure: Baguette french toast

# Business understanding : Automating Cuisine Identification

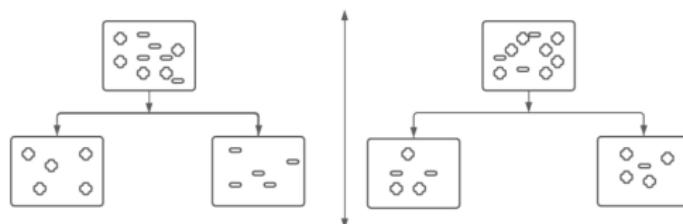
- Definition of the problem and its importance.
  - Identifying the key stakeholders and their objectives.
  - Gathering domain knowledge and understanding business requirements.
- 2- En regardant le diagramme, nous repérons deux caractéristiques remarquables de la méthodologie de la DS. Lesquelles?
- 3- Pouvons-nous prédire la cuisine d'un plat donné en utilisant uniquement le nom du plat ?
- 4- Et en utilisant uniquement l'apparence ? Est-il possible de prédire la cuisine d'un plat donné ?

Automatiser le processus de détermination de la cuisine d'un plat donné n'est donc pas un problème simple.

- 5- Que dire de la détermination de la cuisine d'un plat en fonction de ses ingrédients ?

# Analytic Approach: Automating Cuisine Identification

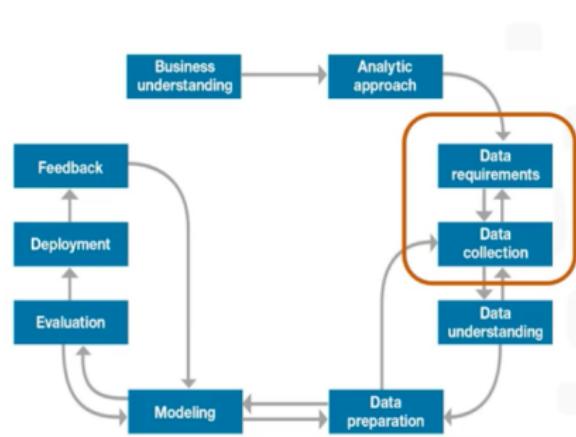
- Questions to consider:
  - ① What are the available data sources?
  - ② Which features can be extracted from the data?
  - ③ Are there existing models or algorithms that can be leveraged?
  - ④ How can the accuracy of the predictions be evaluated?
- Informative Decision Tree:



Conclusion: The goal of this stage is expressing the problem in the context of statistical and ml techniques

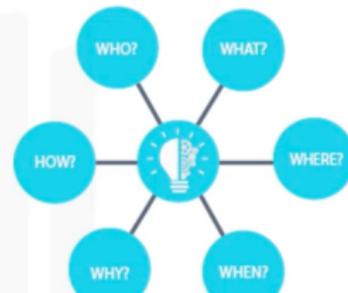
# Requirements

## From Requirements to Collection



### Data Requirements

- What are data requirements?

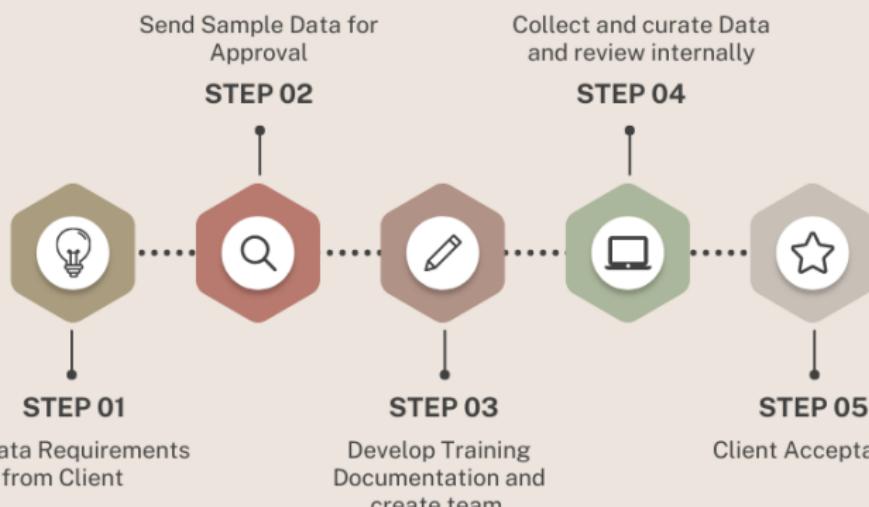


### Data Collection

- What occurs during data collection?

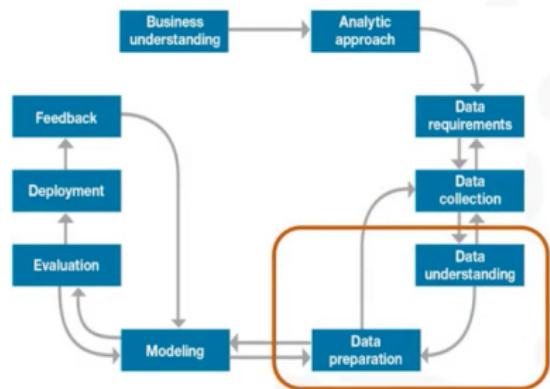
# Data collection for Machine Learning

## Data Collection Workflow



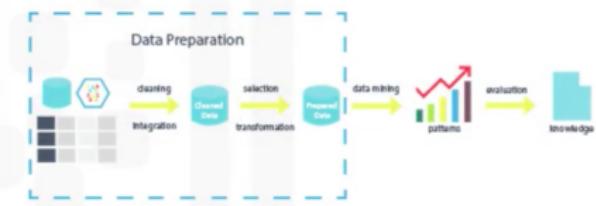
# Data understanding

## From Understanding to Preparation



### Data understanding

- What does it mean to "prepare" or "clean" data?



### Data preparation

- What are ways in which data is prepared?

The data we need to answer the question, **can we automate the process of determining the cuisine of a given recipe?**, is readily available. Researcher **Yong-Yeol Ahn** scraped tens of thousands of food recipes (cuisines and ingredients).

# Data understanding

## Import libraries and download Data

```
1 import pandas as pd # import library to read data
2 pd.set_option('display.max_columns', None)
3 import numpy as np # import numpy library
4 import re # import library for regular expression
5 recipes = pd.read_csv("https://cf-courses-data.s3.us.
6   cloud-object-storage.appdomain.cloud/
7   IBMDeveloperSkillsNetwork-DS0103EN-SkillsNetwork/
8   labs/Module%202/recipes.csv") # 30 s
```

```
1 recipes.head()
2 recipes.shape
3 ingredients = list(recipes.columns.values)
```

# Data understanding

## Description du jeu de données

Notre jeu de données est composé de 57 691 recettes. Chaque ligne représente une recette, et pour chaque recette, la cuisine correspondante est documentée, ainsi que la présence de 384 ingrédients dans la recette. Nous savons qu'une recette de sushi de base comprend les ingrédients suivants :

- Riz
- Sauce soja
- Wasabi
- Du poisson/légumes au choix

# Data Preparation

## Frequency Table

This stage involves exploring the data further and making sure that it is in the right format for the machine learning algorithm that we selected in the analytic approach stage.

```
recipes[ "country" ].value_counts()
```

By looking at the table, we can make the following observations:

- Cuisine column is labeled as Country, which is inaccurate.
- Cuisine names are not consistent as not all of them start with an uppercase first letter.
- Some cuisines are duplicated as variation of the country name, such as Vietnam and Vietnamese.
- Some cuisines have very few recipes.

# Data Preparation

Let's fix these problems

- ① Fix the name of the column showing the cuisine

```
1 column_names = recipes.columns.values
2 column_names[0] = "cuisine"
3 recipes.columns = column_names
```

- ② Make all the cuisine names lowercase

```
1 recipes["cuisine"] = recipes["cuisine"].str.lower()
()
```

- ③ Make the cuisine names consistent.

```
recipes.loc[recipes["cuisine"] == "austria", "cuisine"]
    ] = "austrian"
recipes.loc[recipes["cuisine"] == "belgium", "cuisine"]
    ] = "belgian"
recipes.loc[recipes["cuisine"] == "china", "cuisine"]
    ] = "chinese"
```

# Data Preparation

Let's fix these problems

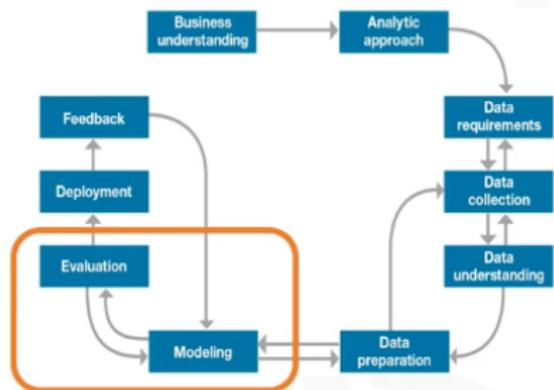
- ① Remove cuisines with < 50 recipes.

```
1 # get list of cuisines to keep
2 recipes_counts = recipes["cuisine"].value_counts()
3 cuisines_indices = recipes_counts > 50
4
5 cuisines_to_keep = list(np.array(recipes_counts.
       index.values)[np.array(cuisines_indices)])
```

```
1 rows_before = recipes.shape[0] # number of rows of
      original dataframe
2 print("Number of rows of original dataframe is {}".
      format(rows_before))
3
4 recipes = recipes.loc[recipes['cuisine'].isin(
      cuisines_to_keep)]
```

# Data Modelling

## From Modeling to Evaluation



### Modeling

- In what way can the data be visualized to get to the answer that is required?*

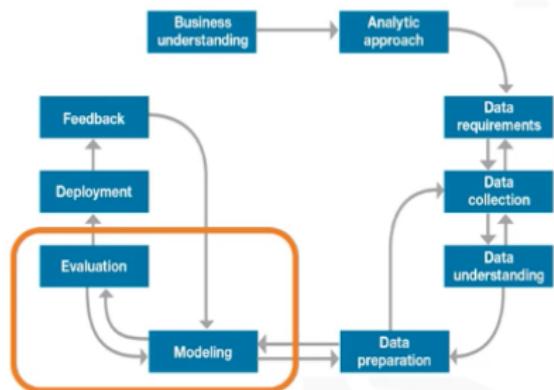


### Evaluation

- Does the model used really answer the initial question or does it need to be adjusted?*

# Data Modelling

## From Modeling to Evaluation



### Modeling

- In what way can the data be visualized to get to the answer that is required?*

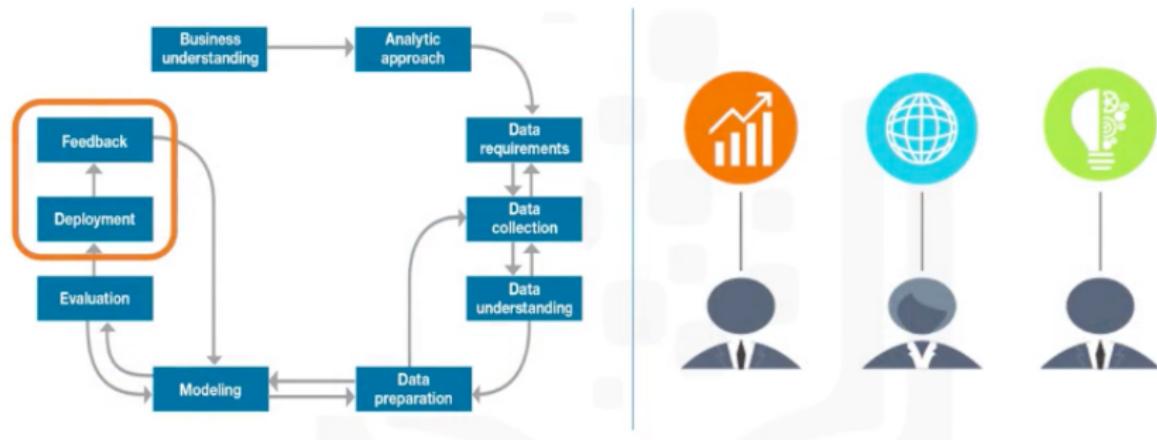


### Evaluation

- Does the model used really answer the initial question or does it need to be adjusted?*

# Model deployment

## From Deployment to Feedback



# Python 2: Avancé



# Introduction aux chatbots

- Présentation des chatbots et de leur utilité dans les applications pratiques
- Compréhension des composants clés d'un chatbot (interfaces, traitements, etc.)
- Exemples d'utilisation de chatbots dans différents domaines (service client, support technique, etc.)
- Introduction aux plateformes de développement de chatbots (Dialogflow, Microsoft Bot Framework, etc.)

# Conception et amélioration des chatbots

- Méthodologies de conception de chatbots conversationnels
- Utilisation des techniques de NLP pour améliorer la compréhension et la génération de réponses
- Optimisation de l'expérience utilisateur des chatbots
- Méthodes d'évaluation et d'amélioration des performances des chatbots

# Machine Learning avec Scikit-Learn

- Introduction à Scikit-Learn comme une bibliothèque populaire de Machine Learning en Python
- Présentation des étapes typiques d'une tâche de Machine Learning avec Scikit-Learn (chargement des données, prétraitement, construction du modèle, évaluation, etc.)
- Présentation des différents types de modèles disponibles dans Scikit-Learn (régression, classification, clustering, etc.)

# Régression linéaire et logistique avec Scikit-Learn

- Utilisation de Scikit-Learn pour effectuer des tâches de régression linéaire et logistique
- Méthodes d'évaluation des modèles de régression et de classification
- Optimisation des hyperparamètres des modèles avec Scikit-Learn

# Clustering avec K-means

- Introduction au clustering comme une technique d'apprentissage non supervisé
- Explication du fonctionnement de l'algorithme K-means
- Utilisation de Scikit-Learn pour effectuer le clustering avec K-means
- Évaluation des résultats de clustering

# Analyse en composantes principales (ACP)

- Introduction à l'analyse en composantes Principales (ACP) comme une technique de réduction de dimension
- Explication du concept de variance expliquée par les composantes principales
- Utilisation de Scikit-Learn pour effectuer l'ACP
- Visualisation des données réduites avec l'ACP

# Plan de présentation

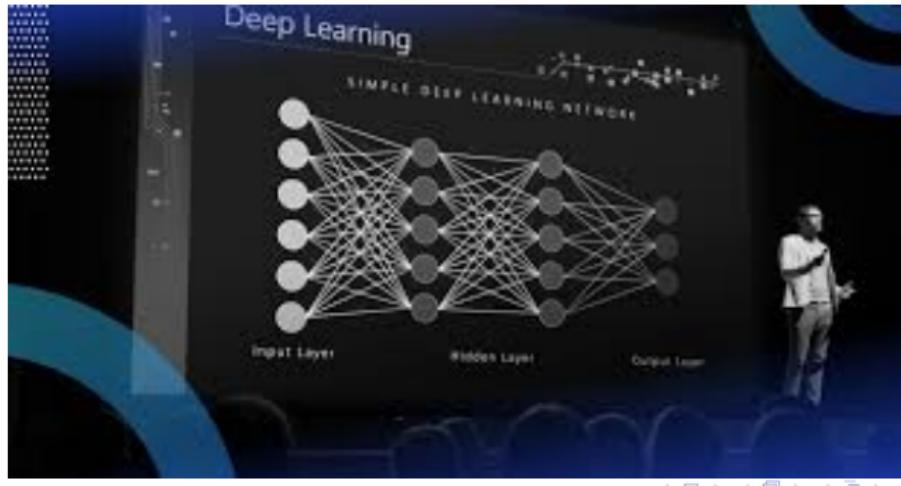
- Régression
- Régression logistique
- Classification des données avec régression logistique
- PNL avancée avec Python pour l'apprentissage automatique
- Révision des bases de la PNL
- Word2Vec
- Doc2Vec
- Réseaux de neurones récurrents
- Comparaison des techniques avancées de PNL sur un problème de ML
- PNL avec Python pour l'apprentissage automatique essentiel
- Formation en PNL de base
- Nettoyage de données supplémentaires
- Vectorisation des données brutes
- Ingénierie des fonctionnalités
- Création de classificateurs d'apprentissage automatique

# Deep Learning and Neural Network



# Plan de présentation

- Apprentissage profond
- Optimisation et réglage du modèle
- Création d'applications de Deep Learning avec TensorFlow
- Réseaux de neurones
- Réseaux de neurones récurrents
- Réseaux de neurones et réseaux de neurones convolutifs



# Réseaux de neurones: Définition

## Biological neuron and Perceptrons

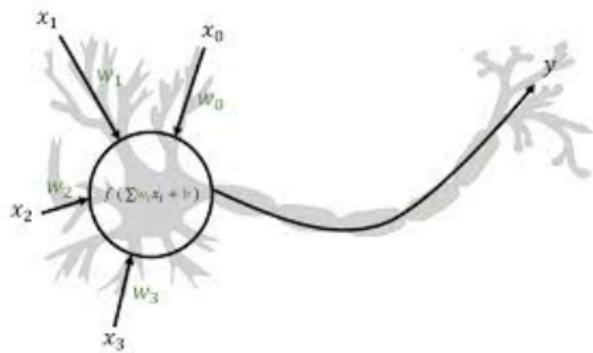
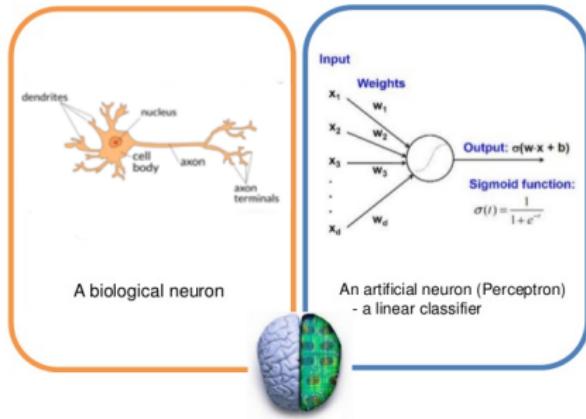
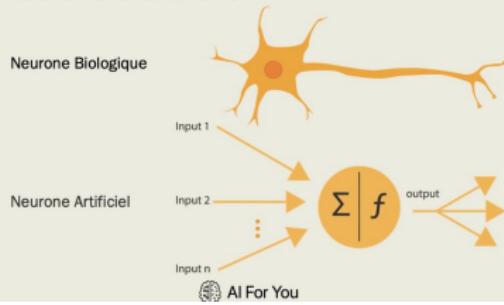


Figure:

Figure:

# Réseaux de neurones: Définition

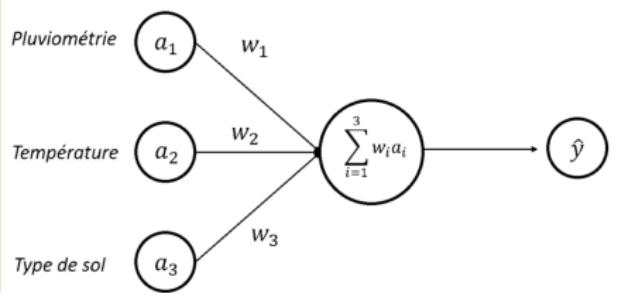
## Neurone artificielle



**Figure:** Neurone biologique et artificiel

Couche d'un neurone

Rendement estimé



**Figure:** Architecture d'un perceptron

# Architecture des réseaux de neurones

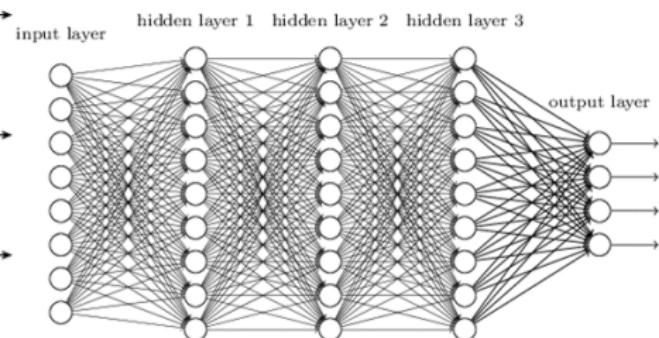
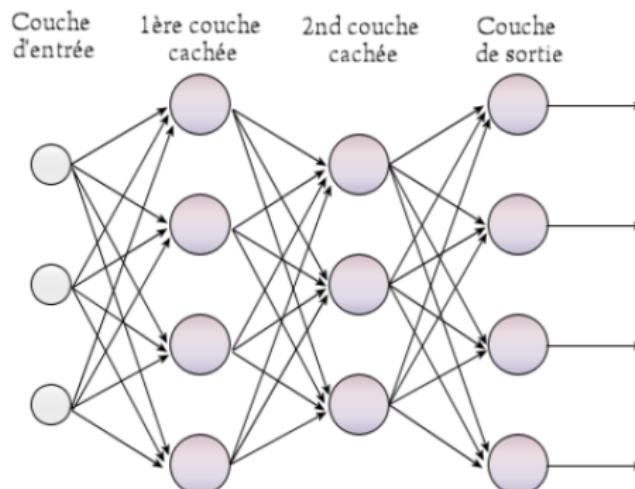


Figure: Perceptron multicouches

Figure: Perceptron à 4 couches

# Apprentissage et rétropropagation

## 1. Propagation avant (Forward propagation)

$$z = \sum_{i=1}^n w_i \cdot x_i + b$$

où  $w_i$  sont les poids associés aux entrées  $x_i$ ,  $b$  est le biais du neurone.  
Ensuite, une fonction d'activation non linéaire  $f(z)$  est appliquée pour obtenir la sortie du neurone :

$$a = f(z)$$

La sortie  $a$  est ensuite transmise aux neurones de la couche suivante.

## 2. Calcul de l'erreur :

Pour un problème de régression, la (MSE) est souvent utilisée :

$$E = \frac{1}{2m} \sum_{i=1}^m (y_i - a_i)^2$$

# Apprentissage et rétropropagation

3. Rétropropagation (Backpropagation) : Les gradients sont utilisés pour mettre à jour les poids et les biais lors de l'étape d'optimisation.

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{ij}}$$

4. Mise à jour des poids et des biais :

$$w_{ij} \leftarrow w_{ij} - \alpha \cdot \frac{\partial E}{\partial w_{ij}}$$

$$b_j \leftarrow b_j - \alpha \cdot \frac{\partial E}{\partial b_j}$$

5. Itérations : Le processus de propagation avant, de rétropropagation et de mise à jour des poids et des biais est répété pour chaque lot (mini-batch) d'exemples d'entraînement.

# Types de réseaux de neurones

- Réseaux de neurones multicouches (MLP) : Utilisés pour la classification et la régression.
- Réseaux de neurones récurrents (RNN) : Traite les données séquentielles avec des boucles de rétroaction.
- Réseaux de neurones convolutifs (CNN) : Analyse les images et les données spatiales.
- Réseaux de neurones LSTM : RNN avec capacité de mémorisation à long terme.
- Réseaux de neurones générateurs adverses (GAN) : Utilisés pour générer des données synthétiques.

# Types de réseaux de neurones

## Réseaux de neurones multicouches (MLP)

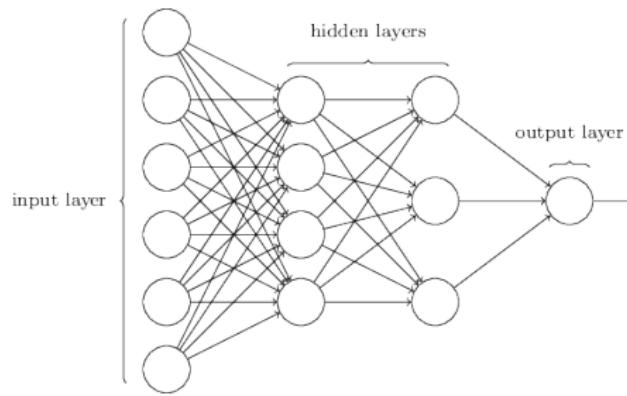


Figure: MLP pour Regression

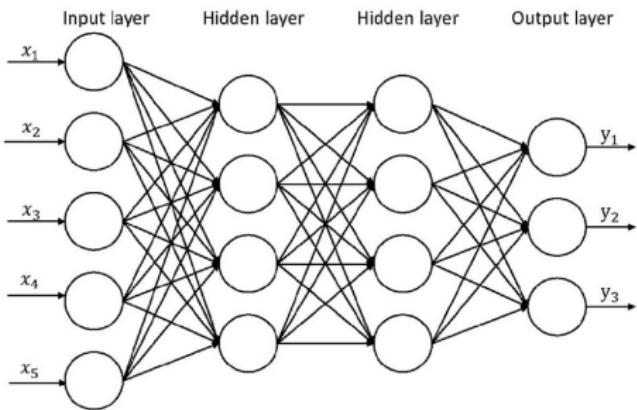


Figure: MLP pour Classification

# Types de réseaux de neurones

## Réseaux de neurones récurrents (RNN)

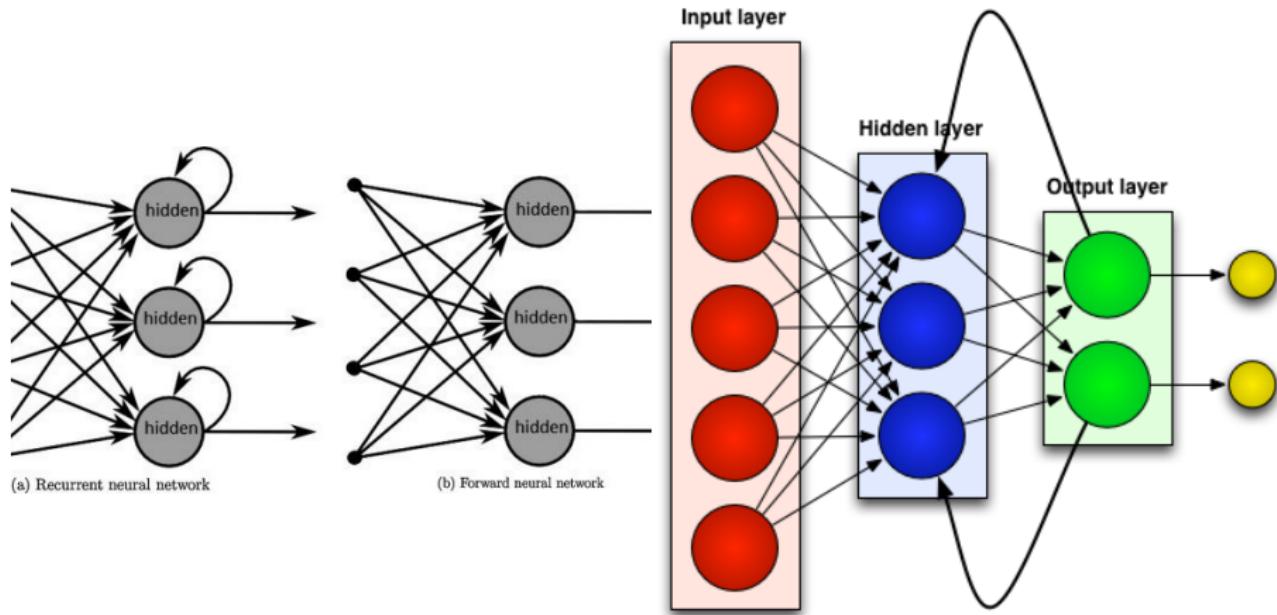


Figure: Traite les données séquentielles avec des boucles de rétroaction.

# Types de réseaux de neurones

## Réseaux de neurones convolutifs (CNN)

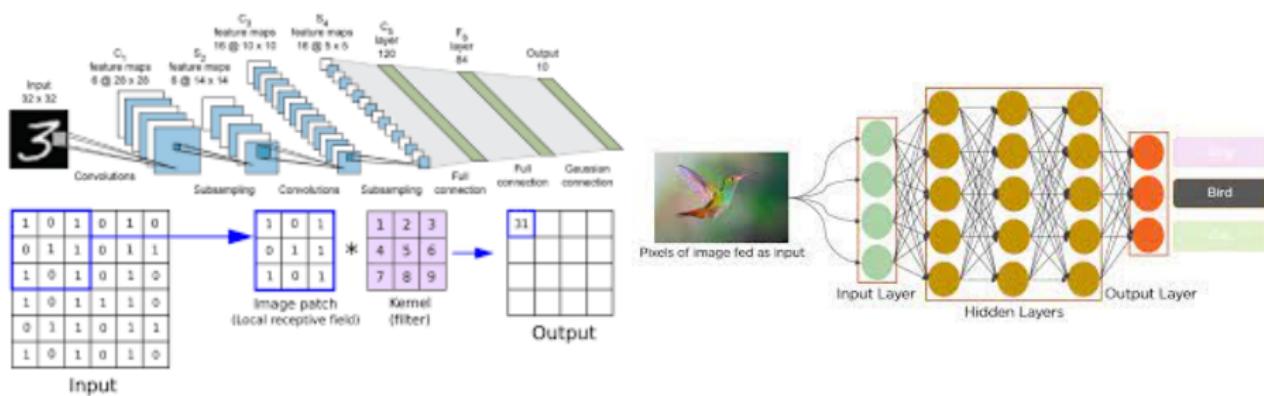


Figure: Analyse les images et les données spatiales.

# Types de réseaux de neurones

## Réseaux de neurones LSTM et GAN

### Long / Short Term Memory (LSTM)

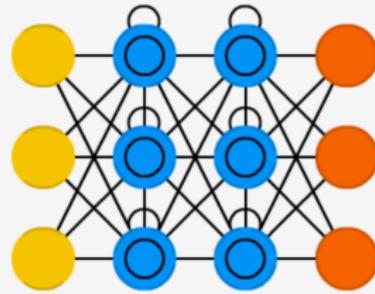


Figure: RNN avec capacité de mémorisation à long terme

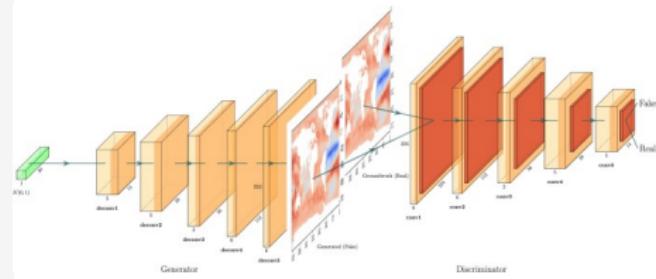


Figure: GAN pour générer des données synthétiques

# Entraînement et évaluation des réseaux de neurones

- Préparation des données :
  - Collecte et préparation des données train, val, test.
  - Division des données en ensembles distincts.
- Définition de l'architecture du réseau de neurones :
  - Choix du type de réseau de neurones.
  - Définition des couches, des neurones, des fonctions d'activation, etc.
- Entraînement du réseau :
  - Propagation avant pour obtenir les prédictions.
  - Calcul de l'erreur et rétropropagation pour ajuster les poids et les biais.
  - Mise à jour des poids et des biais avec un algorithme d'optimisation.
  - Répétition pour plusieurs époques.
- Évaluation du modèle :
  - Évaluation des performances sur l'ensemble de validation.
  - Calcul des métriques d'évaluation.
  - Ajustements sur l'architecture ou les paramètres si nécessaire.

# Principe du Machine Learning

- Systèmes experts
- Réseaux de neurones
- Logique floue
- Méthodes probabilistes

# Systèmes experts

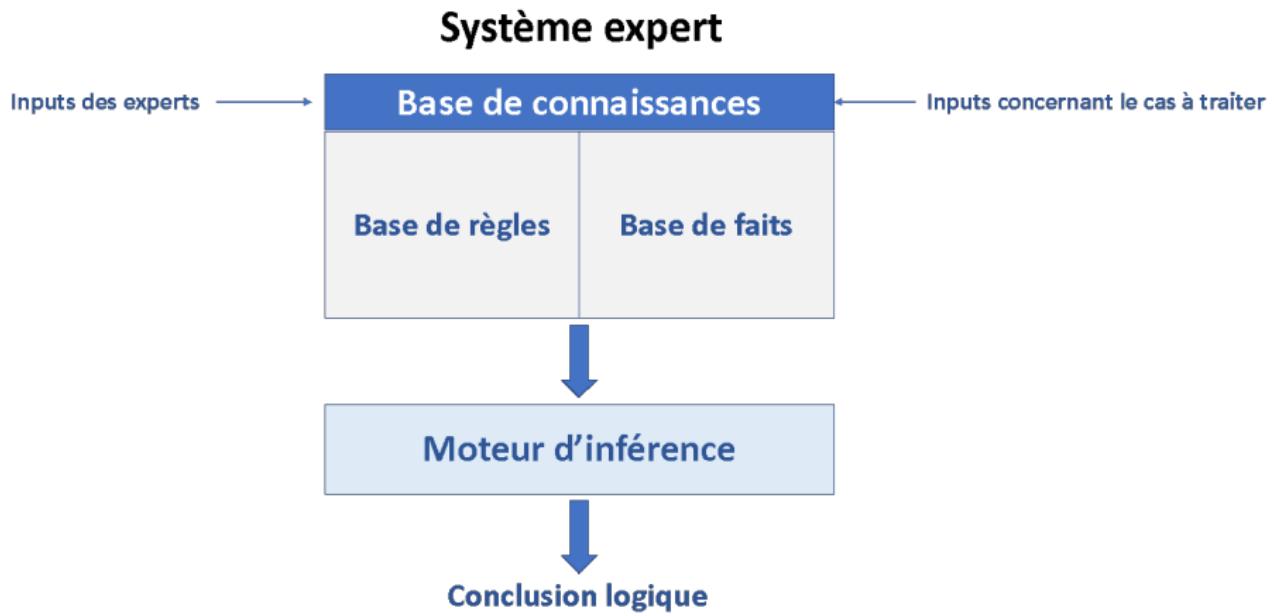
But

- Modélisation (logique) d'un expert humain
- D'une tâche de résolution d'un problème
- Explications sur les raisonnements

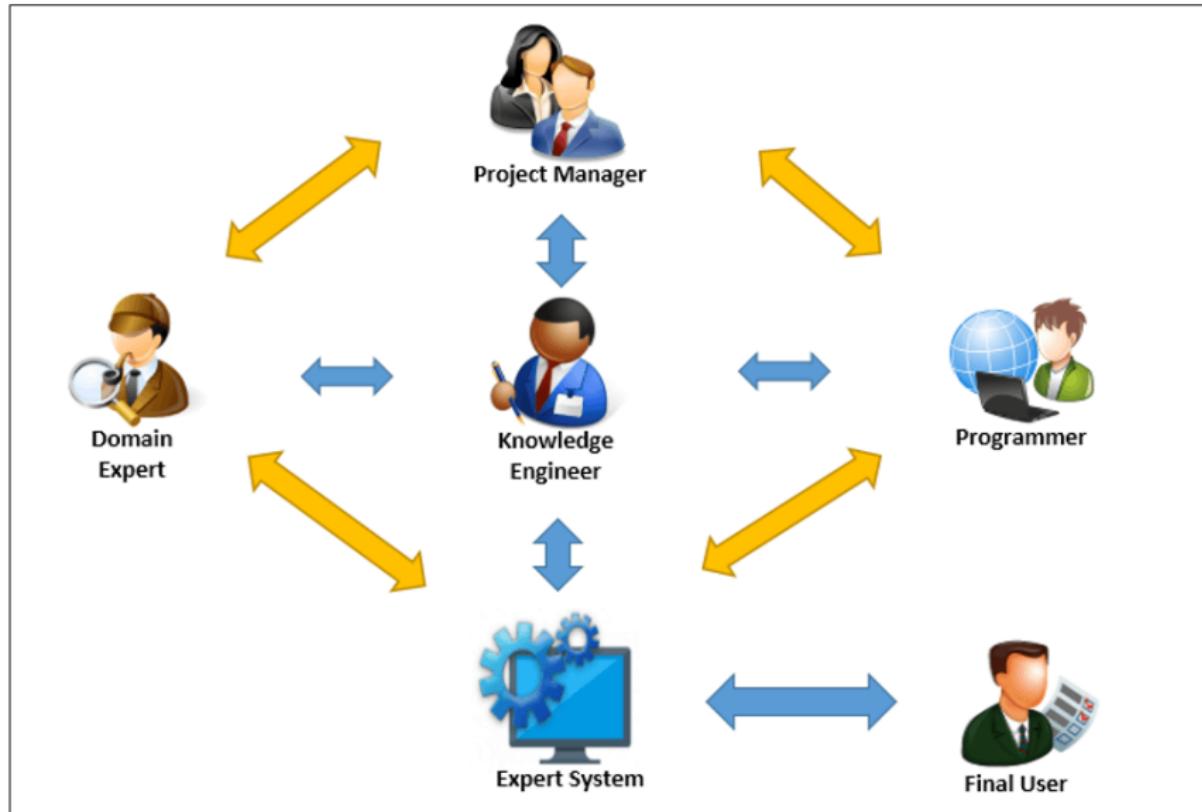
Composition

- Base de connaissance
- Moteur d'inférence

# Systèmes experts



# Systèmes experts



# Entraînement et évaluation des réseaux de neurones

- Évaluation du modèle :
  - Évaluation des performances sur l'ensemble de validation.
  - Calcul des métriques d'évaluation.
  - Ajustements sur l'architecture ou les paramètres si nécessaire.
- Test final du modèle :
  - Évaluation des performances sur l'ensemble de test.
  - Calcul des métriques finales.
- Réglage des hyperparamètres :
  - Expérimentation avec différents hyperparamètres.
  - Utilisation de techniques comme la validation croisée.
- Répétition des étapes 3 à 6 jusqu'à atteindre les performances souhaitées.

# Défis et tendances des réseaux de neurones

# Techniques d'Interprétabilité en Machine Learning (IML)

- Présentation des différentes techniques d'IML
- Méthodes basées sur les modèles linéaires : coefficients, poids attribués aux variables
- Méthodes basées sur les arbres de décision : importance des variables, trajectoires des données
- Autres méthodes : SHAP, LIME, etc.

# Réseaux de neurones et Deep Learning

- Introduction aux réseaux de neurones comme une technique de Machine Learning avancée
- Explication de l'architecture des réseaux de neurones : couches, neurones, fonctions d'activation
- Présentation du Deep Learning comme une extension des réseaux de neurones avec des architectures profondes

# TensorFlow et Keras

- Présentation des frameworks TensorFlow et Keras pour le développement de modèles de Deep Learning
- Explication de l'utilisation de TensorFlow pour la définition des graphes de calcul
- Présentation de Keras comme une interface conviviale pour la construction de modèles de Deep Learning

# Réseaux de neurones récurrents

- Introduction aux réseaux de neurones récurrents (RNN) pour le traitement des données séquentielles
- Explication du fonctionnement des RNN et de la rétropropagation du gradient à travers le temps
- Applications des RNN : traduction automatique, reconnaissance vocale, etc.

# Traitement du langage naturel avec les réseaux de neurones

- Présentation de l'utilisation des réseaux de neurones pour le traitement du langage naturel (NLP)
- Explication des modèles de NLP tels que les réseaux de neurones récurrents (RNN) et les transformers
- Exemples d'applications de NLP : classification de texte, génération de texte, compréhension de texte, etc.

# Application : NLP

# Conclusion

- Récapitulatif des concepts clés abordés dans les techniques avancées de Machine Learning
- Invitation aux questions et discussions

# Applications pratiques de l'IA et du Machine Learning

- Analyse des données avec Power BI
- Utilisation de visuels d'IA pour l'analyse de données
- Introduction aux chatbots
- Conception et amélioration des chatbots
- Machine Learning avec Scikit-Learn
- Régression linéaire et logistique avec Scikit-Learn
- Clustering avec K-means
- Analyse en composantes principales (ACP)

# Analyse des données avec Power BI

- Introduction à Power BI pour l'analyse des données
- Utilisation des fonctionnalités de Power BI pour importer et préparer les données
- Création de visualisations interactives pour l'exploration des données
- Utilisation de Power BI pour générer des insights et des rapports visuels

# Utilisation de visuels d'IA pour l'analyse de données

- Présentation des visuels d'IA disponibles dans Power BI
- Utilisation de la reconnaissance d'images pour l'analyse visuelle des données
- Utilisation de la détection d'anomalies pour identifier les valeurs aberrantes
- Utilisation du service cognitif de Power BI pour l'analyse linguistique des données textuelles